
Convergence de l'algorithme EM

Démonstration de la croissance de la log-vraisemblance observée

Marouane Rida Zaki · Mohammed-Amine Chnidguira

Encadrant : Nathan Gillot

Université de Lorraine — Faculté des Sciences

Le problème : une étiquette manquante

On mesure la taille des nids X ; l'espèce Z qui les a construits reste cachée — c'est la **variable latente** du modèle. La distribution des tailles observées est un mélange de J gaussiennes :

$$f_{\theta}(x) = \sum_{j=1}^J \alpha^{(j)} \gamma_{m^{(j)}, v^{(j)}}(x)$$

Objectif : estimer $\theta = (\alpha^{(j)}, m^{(j)}, v^{(j)})_{1 \leq j \leq J}$ — proportions, moyennes, variances — à partir des **seules** tailles observées.

Deux vraisemblances, une difficulté

Si Z était connu — vraisemblance complète

$$L(\theta; X, Z) = \sum_{i=1}^n \log h_{\theta}(X_i, Z_i)$$

Se sépare proprement par espèce → estimateurs explicites.

En réalité — vraisemblance observée

$$L_{\text{obs}}(\theta; X) = \sum_{i=1}^n \log \left(\sum_{j=1}^J \alpha^{(j)} \gamma_{m^{(j)}, v^{(j)}}(X_i) \right)$$

Un log d'une somme : la maximisation analytique est hors d'atteinte.

L'idée de l'algorithme EM

Remplacer la log-vraisemblance complète $L(\theta; X, Z)$, inaccessible, par son **espérance conditionnelle** sachant les observations. On alterne alors deux étapes :

E Espérance

$$L_c(\theta, \theta_k; X) = \mathbb{E}_{\theta_k} [L(\theta; X, Z) \mid X]$$

M Maximisation

$$\theta_{k+1} = \arg \max_{\theta} L_c(\theta, \theta_k; X)$$

On répète E puis M jusqu'à stabilisation. Reste la question centrale : *pourquoi cela améliore-t-il L_{obs} ?*

ÉNONCÉ

Le théorème de croissance

THÉORÈME — CROISSANCE DE LA VRAISEMBLANCE OBSERVÉE

La suite $(\theta_k)_{k \geq 0}$ construite par l'algorithme EM vérifie, à chaque itération,

$$L_{\text{obs}}(\theta_{k+1}; X) \geq L_{\text{obs}}(\theta_k; X).$$

Autrement dit, la vraisemblance des données observées **ne décroît jamais**.

Fil de la démonstration

- 1 Décomposer la vraisemblance complète : $L_c = L_{\text{obs}} + H$.
- 2 Invoquer l'étape M : $L_c(\theta_{k+1}, \theta_k) \geq L_c(\theta_k, \theta_k)$.
- 3 Soustraire pour minorer $L_{\text{obs}}(\theta_{k+1}) - L_{\text{obs}}(\theta_k)$.
- 4 Reconnaître une divergence de Kullback–Leibler ≥ 0 .
- 5 Conclure : L_{obs} croît à chaque itération.

Une décomposition fondamentale

La densité jointe se factorise, $h_{\theta}(x, z) = f_{\theta}(x) g_{\theta}(z \mid x)$; en passant au logarithme :

$$\log h_{\theta}(x, z) = \log f_{\theta}(x) + \log g_{\theta}(z \mid x)$$

En prenant l'espérance conditionnelle sous θ_k , il vient pour tout θ :

$$L_c(\theta, \theta_k; X) = L_{\text{obs}}(\theta; X) + H(\theta, \theta_k)$$

avec $H(\theta, \theta_k) = \mathbb{E}_{\theta_k}[\log g_{\theta}(Z \mid X) \mid X]$ – identité valable pour **tout** θ .

La garantie de l'étape M

Par définition, θ_{k+1} **maximise** $L_c(\cdot, \theta_k)$. En particulier, sa valeur en θ_{k+1} dépasse celle en θ_k :

$$L_c(\theta_{k+1}, \theta_k; X) \geq L_c(\theta_k, \theta_k; X)$$

C'est tout ce qu'on demande à l'étape M — aucune autre hypothèse.

Faire apparaître L_{obs}

On applique la décomposition de l'étape 1 en θ_{k+1} puis en θ_k :

$$L_c(\theta_{k+1}, \theta_k) = L_{\text{obs}}(\theta_{k+1}) + H(\theta_{k+1}, \theta_k)$$

$$L_c(\theta_k, \theta_k) = L_{\text{obs}}(\theta_k) + H(\theta_k, \theta_k)$$

En injectant dans l'inégalité de l'étape M et en réarrangeant :

$$L_{\text{obs}}(\theta_{k+1}) - L_{\text{obs}}(\theta_k) \geq H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k)$$

Il reste à montrer que le terme de droite est ≥ 0 .

Le terme restant est positif

Ce terme est l'espérance d'un logarithme de rapport — une divergence entre lois a posteriori :

$$H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k) = \mathbb{E}_{\theta_k} \left[\log \frac{g_{\theta_k}(Z|X)}{g_{\theta_{k+1}}(Z|X)} \right] = D(\mu_{\theta_k} \parallel \mu_{\theta_{k+1}})$$

Par l'inégalité de Jensen (la fonction $\log$ est concave) :

$$\mathbb{E}_{\theta_k} \left[\log \frac{g_{\theta_{k+1}}}{g_{\theta_k}} \right] \leq \log \mathbb{E}_{\theta_k} \left[\frac{g_{\theta_{k+1}}}{g_{\theta_k}} \right] = \log 1 = 0$$

donc $D(\mu_{\theta_k} \parallel \mu_{\theta_{k+1}}) \geq 0$ — une divergence de Kullback-Leibler est toujours positive.

La vraisemblance ne décroît jamais

En combinant les étapes 3 et 4, la différence est minorée par une quantité positive :

$$L_{\text{obs}}(\theta_{k+1}) - L_{\text{obs}}(\theta_k) \geq D(\mu_{\theta_k} \parallel \mu_{\theta_{k+1}}) \geq 0$$

$$L_{\text{obs}}(\theta_{k+1}; X) \geq L_{\text{obs}}(\theta_k; X)$$



La log-vraisemblance observée croît à chaque itération de l'EM.

Le schéma de la preuve

L'étape M fait croître L_c

$$L_c(\theta_{k+1}, \theta_k) \geq L_c(\theta_k, \theta_k)$$

↓

décomposition $L_c = L_{\text{obs}} + H$

$$L_{\text{obs}}(\theta_{k+1}) - L_{\text{obs}}(\theta_k) \geq H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k)$$

↓

inégalité de Jensen

$$H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k) = D(\mu_{\theta_k} \parallel \mu_{\theta_{k+1}}) \geq 0$$

$$L_{\text{obs}}(\theta_{k+1}) \geq L_{\text{obs}}(\theta_k)$$

Ce que la monotonie garantit

CE QUI EST GARANTI

La suite $(L_{\text{obs}}(\theta_k))_k$ est croissante et majorée.

Elle converge donc vers une limite $L^* \in \mathbb{R}$.

Stabilité numérique : pas d'oscillation, pas de chute.

CE QUI NE L'EST PAS

La suite des paramètres (θ_k) peut ne pas converger.

Sa limite n'est pas forcément un point stationnaire.

Ni a fortiori un maximum global — maxima locaux, sensibilité à l'initialisation.

Trois niveaux de convergence

Monotonie
ce travail

Les valeurs $L_{\text{obs}}(\theta_k)$ croissent et convergent vers L^* .

**Dempster–Laird–
Rubin**
1977

Si $\theta_k \rightarrow \theta^*$, alors $\nabla L_{\text{obs}}(\theta^*) = 0$ — ils disent *où*, pas *si*.

Wu
1983

Sous compacité, tout point d'accumulation est stationnaire — vrai pour les mélanges gaussiens (famille exponentielle).

CONCLUSION

Merci.

La monotonie de L_{obs} fonde la stabilité de l'EM ; Dempster–Laird–Rubin et Wu en complètent la convergence.

Questions ?

Marouane Rida Zaki · Mohammed-Amine Chnidguira — TER M1 IMSD