

Algorithme EM

Expectation-Maximization

Application aux mélanges gaussiens

Ce document présente l'algorithme EM (Expectation-Maximization), une méthode itérative d'estimation par maximum de vraisemblance en présence de variables latentes. L'application aux mélanges de lois gaussiennes est illustrée par un modèle de classification de nids de mouettes selon leur taille. Les méthodes développées sont validées sur des données simulées et appliquées à des données réelles.

AUTEUR

Marouane Rida Zaki
Mohammed-Amine Chnidguira
M1 IMSD

ENCADRANT

Nathan Gillot
Université de Lorraine

Table des matières

Introduction	2
1 Modèle pour les nids de mouettes	2
1. Modélisation par un mélange de lois gaussiennes	3
2. Variable latente et structure probabiliste du modèle	4
3. Échantillon observé et espace des paramètres	4
4. Densités jointe, marginales et conditionnelles	4
2 Situation favorable mais irréaliste	6
2.1 Estimation de $\alpha^{(j)}$	9
2.2 Estimation de $m^{(j)}$	10
2.3 Estimation de $v^{(j)}$	10
2.4 Limite du modèle complet et introduction de la vraisemblance observée	11
3 Résolution du vrai problème	12
Théorème (Log-vraisemblance conditionnelle)	13
Théorème (Maximum de la log-vraisemblance conditionnelle)	14
Estimer $\alpha(j)$	14
Estimation de $m(j)$	15
Estimation de $v(j)$	16
Théorème Croissance de la vraisemblance observée	17
Limites du résultat de monotonie	20
Convergence vers un point stationnaire (Dempster, Laird et Rubin, 1977)	21
Conditions suffisantes de convergence (Wu, 1983)	22
Synthèse et conséquences pratiques	23
4 Applications numériques	24
4.1 Données simulées	24
4.1.1 Validation sur données simulées	24
4.1.2 Influence du nombre de composantes	26
4.1.3 Comportement face à des composantes proches	27
4.1.4 Influence de la taille de l'échantillon	28
4.1.5 Sensibilité à l'initialisation et permutation des étiquettes	28
4.2 Données réelles	30
4.2.1 Application sur le dataset Iris	30
Références	30

Introduction

Algorithme EM (Expectation-Maximization)

Formalisé en 1977 par Dempster, Laird et Rubin, l'algorithme EM (Expectation-Maximization) est une méthode itérative permettant d'estimer les paramètres d'un modèle probabiliste en présence de données incomplètes ou de variables latentes. Il alterne deux étapes : une étape E (Expectation), qui calcule l'espérance de la vraisemblance complète conditionnellement aux données observées et aux paramètres courants, et une étape M (Maximization), qui maximise cette espérance pour mettre à jour les paramètres. Ces deux étapes sont répétées jusqu'à convergence.

Sur une île vivent plusieurs espèces de mouettes. Les ornithologues cherchent à connaître la proportion de chacune d'elles dans la population. Compter directement les oiseaux n'est pas simple : ils volent, se déplacent, se cachent. Les nids, eux, restent en place, et c'est par eux qu'on va passer pour remonter à l'information recherchée.

Le problème, c'est que les nids des différentes espèces se ressemblent trop pour qu'on puisse les distinguer à l'œil nu. En revanche, chaque espèce a ses propres habitudes de construction, et la taille des nids varie d'une espèce à l'autre selon une distribution qui lui est propre, avec sa moyenne et sa dispersion caractéristiques. La taille du nid est donc la seule variable observable, tandis que l'espèce qui l'a construit reste cachée.

La distribution globale des tailles observées apparaît alors comme un mélange des distributions individuelles, pondérées par les proportions des espèces. À partir de ces seules mesures, l'objectif est de retrouver ces proportions cachées ainsi que les paramètres propres à chaque espèce. C'est précisément le type de situation que l'algorithme EM permet de traiter.

On modélise la distribution totale des tailles observées comme un mélange de J lois :

$$f(x) = \sum_{j=1}^J \alpha(j) f_j(x),$$

où $f_j(x)$ représente la loi de probabilité de la taille des nids pour l'espèce j , et $\alpha(j)$ la proportion de cette espèce sur l'île. Les proportions vérifient naturellement $\alpha(j) > 0$ et $\sum_{j=1}^J \alpha(j) = 1$, puisqu'elles décrivent une répartition complète de la population.

Les proportions $\alpha(j)$ ainsi que les paramètres caractérisant chacune des lois f_j sont inconnus : ce sont précisément eux que l'on cherche à estimer à partir des seules tailles observées.

1 Modèle pour les nids de mouettes

Loi gaussienne

La loi gaussienne, également appelée loi normale, est une loi de probabilité continue très utilisée en statistique pour modéliser des phénomènes naturels ou des variables aléatoires résultant de nombreux effets indépendants. Elle est entièrement caractérisée par deux paramètres : la moyenne μ , qui représente la valeur centrale autour de laquelle les observations se répartissent, et la variance σ^2 , qui mesure la dispersion des données autour de cette moyenne.

Sa densité de probabilité est donnée par :

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

La représentation graphique de cette loi est une courbe en forme de cloche, symétrique par rapport à la moyenne. On note généralement

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

Dans cette section, nous formalisons le modèle statistique utilisé pour décrire la distribution de la taille des nids observés sur l'île. L'objectif est d'estimer la proportion de chaque espèce de mouettes ainsi que les caractéristiques propres à leurs nids, à partir des seules mesures de tailles disponibles.

Mélange fini de lois

est une loi de probabilité de densité :

$$f_X(x) = \sum_{j=1}^J \alpha^{(j)} f_j(x),$$

où $f_1, \dots, f_J$ sont des densités de probabilité et $\alpha^{(1)}, \dots, \alpha^{(J)}$ sont des poids vérifiant $\alpha^{(j)} > 0$ et $\sum_{j=1}^J \alpha^{(j)} = 1$.

Une représentation équivalente fait intervenir une variable latente Z à valeurs dans $\{1, \dots, J\}$ telle que $P(Z = j) = \alpha^{(j)}$ et $X \mid Z = j \sim f_j$.

1. Modélisation par un mélange de lois gaussiennes

On suppose que l'île abrite J espèces distinctes de mouettes. Chaque espèce construit des nids dont la taille suit une distribution spécifique.

Pour $j \in \{1, \dots, J\}$, on modélise la taille des nids construits par l'espèce j par une loi normale

$$\mathcal{N}(m(j), v(j)),$$

de densité

$$\gamma_{m(j), v(j)}(x) = \frac{1}{\sqrt{2\pi v(j)}} \exp\left(-\frac{(x - m(j))^2}{2v(j)}\right).$$

Les paramètres $m(j)$ et $v(j)$ représentent respectivement la moyenne et la variance des tailles de nids de l'espèce j .

On note $\alpha(j)$ la proportion de l'espèce j dans la population totale, avec

$$\alpha(j) > 0, \quad \sum_{j=1}^J \alpha(j) = 1.$$

La distribution globale des tailles de nids apparaît alors comme un *mélange fini de lois gaussiennes*, de densité

$$f_{\theta}(x) = \sum_{j=1}^J \alpha(j) \gamma_{m(j),v(j)}(x), \quad \text{où} \quad \theta = (\alpha(j), m(j), v(j))_{1 \leq j \leq J} \quad (1)$$

désigne l'ensemble des paramètres inconnus du modèle.

Ce type de combinaison convexe de densités est appelé *mélange fini de populations*.

2. Variable latente et structure probabiliste du modèle

Introduisons deux variables aléatoires :

- X : la taille d'un nid observé ;
- $Z \in \{1, \dots, J\}$: l'espèce de la mouette ayant construit ce nid.

La variable Z est *non observée* : elle constitue la variable latente du modèle.

La structure probabiliste est définie comme suit :

1. La variable Z suit une loi discrète sur $\{1, \dots, J\}$:

$$\mathbb{P}(Z = j) = \alpha(j).$$

2. Conditionnellement à $\{Z = j\}$, la variable X suit une loi normale de paramètres $m(j)$ et $v(j)$:

$$X \mid Z = j \sim \mathcal{N}(m(j), v(j)).$$

Cette modélisation signifie que la taille d'un nid est d'abord déterminée par le choix aléatoire de l'espèce (selon les proportions $\alpha(j)$), puis par une réalisation gaussienne propre à cette espèce.

3. Échantillon observé et espace des paramètres

On observe les tailles $x_1, \dots, x_n$, supposées être la réalisation d'un échantillon i.i.d. $X_1, \dots, X_n$ de densité f_{θ} . L'ensemble des paramètres admissibles est

$$\Theta = \left\{ \theta = (\alpha(j), m(j), v(j))_{1 \leq j \leq J} : \alpha(j) > 0, \sum_{j=1}^J \alpha(j) = 1 \right\}.$$

Le problème statistique consiste à estimer le paramètre $\theta \in \Theta$ à partir des seules observations $x_1, \dots, x_n$, sans connaître les valeurs correspondantes de $Z_1, \dots, Z_n$.

4. Densités jointe, marginales et conditionnelles

On note $d\lambda$ la mesure de Lebesgue sur $\mathbb{R}$ et dN la mesure de comptage sur $\{1, \dots, J\}$.

On définit la densité jointe du couple (X, Z) par rapport à la mesure produit $d\lambda \otimes dN$, notée h_{θ} , par :

$$h_{\theta}(x, z) = \alpha(z) \gamma_{m(z),v(z)}(x), \quad x \in \mathbb{R}, \quad z \in \{1, \dots, J\}. \quad (2)$$

Cette fonction caractérise entièrement la loi jointe de la taille observée X et de l'espèce latente Z : le facteur $\alpha(z)$ correspond à la probabilité de l'espèce z , tandis que $\gamma_{m(z),v(z)}(x)$ donne la densité de la taille sachant cette espèce.

À partir de cette densité jointe, on retrouve respectivement les densités marginales de X et de Z . La densité marginale de X est donnée par (1), et la densité marginale de Z est $g_{\theta}(z) = \alpha(z)$. La densité de X correspond bien à un mélange gaussien, tandis que celle de Z se réduit aux

proportions $\alpha(j)$. On en déduit également la densité conditionnelle de X sachant $Z = j$:

$$f_{\theta}(x \mid Z = j) = \gamma_{m(j),v(j)}(x),$$

qui n'est autre que la densité gaussienne associée à la composante j .

Réciproquement, la densité au point z de la loi de Z sachant $X = x$, par rapport à la mesure de comptage dN , est

$$g_{\theta}(j \mid X = x) = \frac{\alpha(j)\gamma_{m(j),v(j)}(x)}{\sum_{l=1}^J \alpha(l)\gamma_{m(l),v(l)}(x)}. \quad (3)$$

Cette quantité s'obtient par application directe de la formule de Bayes, que nous rappelons ci-dessous avant d'établir le résultat.

Formule de Bayes

La formule de Bayes permet de calculer la probabilité d'un événement A sachant qu'un événement B est réalisé. Elle s'écrit :

$$P(A \mid B) = \frac{P(B \mid A) P(A)}{P(B)}, \quad \text{avec } P(B) > 0.$$

Elle permet d'actualiser une probabilité a priori $P(A)$ à partir d'une information nouvelle B .

Démonstration. Soit $A \in \mathcal{B}(\mathbb{R})$ et soit $j \in \{1, \dots, J\}$. Par la règle des probabilités conditionnelles,

$$\mathbb{P}_{\theta}(X \in A, Z = j) = \mathbb{P}_{\theta}(Z = j) \mathbb{P}_{\theta}(X \in A \mid Z = j).$$

Or, sachant $\{Z = j\}$, la variable X suit la loi $\mathcal{N}(m(j), v(j))$, donc

$$\mathbb{P}_{\theta}(X \in A \mid Z = j) = \int_A \gamma_{m(j),v(j)}(x) dx.$$

On en déduit que

$$\mathbb{P}_{\theta}(X \in A, Z = j) = \alpha(j) \int_A \gamma_{m(j),v(j)}(x) dx.$$

Cela signifie que la densité du couple (X, Z) par rapport à $d\lambda \otimes dN$ est bien la densité jointe (2). En sommant la densité jointe (2) sur $j \in \{1, \dots, J\}$, on retrouve la densité marginale de X , c'est-à-dire la densité du mélange (1).

D'autre part la formule de bayes donne,

$$g_{\theta}(z \mid X = x) = \mathbb{P}_{\theta}(Z = z \mid X = x) = \frac{h_{\theta}(x, z)}{f_{\theta}(x)}, \quad z \in \{1, \dots, J\},$$

dès que $f_{\theta}(x) > 0$. En remplaçant h_{θ} et f_{θ} par leurs expressions, on obtient bien la formule de responsabilité (3).

□

Cette quantité peut être interprétée comme une probabilité d'appartenance de la composante j pour l'observation x .

2 Situation favorable mais irréaliste

Avant de procéder à l'estimation des paramètres dans ce cadre favorable, rappelons brièvement le principe de la méthode du maximum de vraisemblance, qui constitue le fondement de notre approche.

Méthode du maximum de vraisemblance

La méthode du maximum de vraisemblance est une technique d'estimation paramétrique permettant de déterminer les paramètres inconnus d'un modèle probabiliste à partir d'un échantillon observé.

Le principe consiste à choisir les valeurs des paramètres qui rendent les données observées les plus probables. Si $X_1, \dots, X_n$ sont des observations supposées indépendantes et identiquement distribuées selon une loi de paramètre θ , on définit la fonction de vraisemblance par :

$$\mathcal{L}(\theta) = \prod_{i=1}^n f_{\theta}(X_i).$$

L'estimateur du maximum de vraisemblance est alors la valeur $\hat{\theta}$ qui maximise cette fonction, c'est-à-dire :

$$\hat{\theta} = \arg \max_{\theta} \mathcal{L}(\theta).$$

Cette méthode est particulièrement utilisée en statistique et en apprentissage automatique, notamment dans le cadre des modèles de mélange et de l'algorithme EM.

Dans cette section, on considère un cas idéal où l'on observe simultanément la taille des nids X et l'espèce correspondante Z . Cette hypothèse rend l'estimation des paramètres du mélange particulièrement simple, car on peut appliquer directement la méthode du maximum de vraisemblance au modèle complet (X, Z) .

Cette situation est dite favorable, car elle conduit à des estimateurs explicites des proportions, moyennes et variances. Toutefois, elle demeure irréaliste en pratique, puisque seules les tailles des nids sont observées.

Dans cette section idéale, on suppose que chaque nid de l'échantillon nous arrive avec une étiquette indiquant l'espèce qui l'a construit. Concrètement, on dispose donc d'un échantillon de taille n formé de couples

$$(X_1, Z_1), (X_2, Z_2), \dots, (X_n, Z_n),$$

où X_i désigne la taille du i -ème nid et $Z_i \in \{1, \dots, J\}$ l'espèce qui l'a construit. Autrement dit, on connaît à la fois la donnée observable et la variable latente, ce qui n'arrivera évidemment jamais en pratique, mais cela va nous permettre de poser tranquillement les calculs.

D'après la formule (2), la densité jointe du couple (X, Z) est $h_{\theta}(x, z) = \alpha(z) \gamma_{m(z), v(z)}(x)$. Cette expression a une interprétation très naturelle. Le facteur $\alpha(z) = \mathbb{P}(Z = z)$ représente la proportion de l'espèce z sur l'île, c'est-à-dire la probabilité de tomber sur un nid de cette espèce. Le second facteur, $\gamma_{m(z), v(z)}(x)$, donne la densité gaussienne de la taille x sachant que le nid a été construit par l'espèce z . Tirer un nid revient ainsi à effectuer deux opérations successives : on choisit d'abord une espèce selon la loi α , puis on tire une taille selon la gaussienne propre à cette espèce.

Pour alléger les écritures, on notera $\overline{X} = (X_1, \dots, X_n)$ le vecteur des tailles observées et $\overline{Z} = (Z_1, \dots, Z_n)$ le vecteur des espèces correspondantes.

Les observations étant supposées indépendantes et identiquement distribuées, la densité jointe de l'échantillon complet $(\overline{X}, \overline{Z})$ est le produit des densités individuelles :

$$\prod_{i=1}^n h_{\theta}(X_i, Z_i).$$

Comme il est plus pratique de travailler avec des sommes qu'avec des produits, on passe au logarithme pour obtenir la log-vraisemblance :

$$L(\theta, \overline{X}, \overline{Z}) = \log \left(\prod_{i=1}^n h_{\theta}(X_i, Z_i) \right) = \sum_{i=1}^n \log h_{\theta}(X_i, Z_i). \quad (4)$$

On remplace maintenant h_{θ} par son expression. En utilisant (2), on a $h_{\theta}(X_i, Z_i) = \alpha(Z_i) \gamma_{m(Z_i), v(Z_i)}(X_i)$, et le logarithme transforme le produit en une somme :

$$\log h_{\theta}(X_i, Z_i) = \log \alpha(Z_i) + \log \gamma_{m(Z_i), v(Z_i)}(X_i),$$

ce qui donne pour la log-vraisemblance complète :

$$L(\theta, \overline{X}, \overline{Z}) = \sum_{i=1}^n \left[\log \alpha(Z_i) + \log \gamma_{m(Z_i), v(Z_i)}(X_i) \right].$$

Cette écriture met en évidence un point important : la log-vraisemblance se sépare proprement en deux blocs indépendants, l'un dépendant uniquement des proportions α , et l'autre uniquement des moyennes et variances (m, v) des gaussiennes. Cette séparation va nous permettre de traiter chaque famille de paramètres de son côté.

Pour exploiter cette séparation, il est commode de réorganiser la somme en regroupant les observations par espèce. Pour chaque $j \in \{1, \dots, J\}$, on note

$$A_j = \{i \in \{1, \dots, n\} : Z_i = j\}$$

l'ensemble des indices des nids construits par l'espèce j , et

$$C_j = \text{card}(A_j)$$

le nombre de nids attribués à cette espèce dans l'échantillon.

Afin de rendre la dépendance en chaque paramètre explicite et de faciliter la maximisation, on réorganise cette somme en regroupant les observations selon leur espèce d'appartenance. À ce stade, la log-vraisemblance complète s'écrit

$$L(\theta, \overline{X}, \overline{Z}) = \sum_{i=1}^n \log \alpha(Z_i) + \sum_{i=1}^n \log \gamma_{m(Z_i), v(Z_i)}(X_i),$$

où la sommation porte sur les observations $i = 1, \dots, n$. Sous cette forme, les paramètres $\alpha(j)$, $m(j)$ et $v(j)$ n'apparaissent pas de manière isolée : ils sont mélangés à travers les indices Z_i , qui varient d'une observation à l'autre. Pour rendre la dépendance en chaque paramètre explicite, on procède à un changement d'ordre de sommation, en regroupant les observations selon l'espèce à laquelle elles sont rattachées. C'est précisément à cela que servent les ensembles A_j et les

effectifs C_j introduits précédemment.

Réorganisation de la partie en α . Considérons la somme

$$\sum_{i=1}^n \log \alpha(Z_i).$$

Chaque terme $\log \alpha(Z_i)$ prend l'une des J valeurs $\log \alpha(1), \dots, \log \alpha(J)$, selon la valeur de Z_i . Par définition de C_j , la valeur $\log \alpha(j)$ apparaît exactement C_j fois dans la somme, à savoir une fois pour chaque indice $i \in A_j$. On peut donc factoriser :

$$\sum_{i=1}^n \log \alpha(Z_i) = \sum_{j=1}^J C_j \log \alpha(j).$$

On est ainsi passé d'une somme indexée par les observations à une somme indexée par les espèces, dans laquelle chaque espèce j contribue proportionnellement à son effectif C_j dans l'échantillon.

Réorganisation de la partie gaussienne. On procède de manière analogue pour la somme

$$\sum_{i=1}^n \log \gamma_{m(Z_i), v(Z_i)}(X_i),$$

avec toutefois une différence importante : le terme $\log \gamma_{m(j), v(j)}(X_i)$ dépend non seulement de l'espèce j via les paramètres $(m(j), v(j))$, mais aussi de la valeur particulière de l'observation x_i . On ne peut donc pas se contenter de compter les occurrences comme précédemment. En revanche, on peut encore regrouper les observations par espèce, en remarquant que, pour tout $i \in A_j$, on a $Z_i = j$, et donc $m(Z_i) = m(j)$ et $v(Z_i) = v(j)$. Il vient alors :

$$\sum_{i=1}^n \log \gamma_{m(Z_i), v(Z_i)}(X_i) = \sum_{j=1}^J \sum_{i \in A_j} \log \gamma_{m(j), v(j)}(X_i).$$

La somme externe parcourt les espèces, tandis que la somme interne porte uniquement sur les observations rattachées à l'espèce courante. Les paramètres $(m(j), v(j))$, désormais fixés à l'extérieur de la somme interne, n'apparaissent plus que dans le bloc correspondant à l'espèce j .

En réunissant les deux expressions, la log-vraisemblance complète prend la forme

$$L(\theta, \bar{X}, \bar{Z}) = \sum_{j=1}^J C_j \log \alpha(j) + \sum_{j=1}^J \sum_{i \in A_j} \log \gamma_{m(j), v(j)}(X_i).$$

Cette forme réindexée de la log-vraisemblance complète révèle une propriété supplémentaire : non seulement les proportions $\alpha(j)$ et les paramètres gaussiens $(m(j), v(j))$ sont séparés en deux blocs distincts, mais à l'intérieur du second bloc, les espèces sont elles-mêmes découplées : la contribution de l'espèce j ne dépend que de ses propres paramètres et des observations qui lui sont attribuées, sans faire intervenir les autres espèces. La maximisation de L par rapport à θ se ramène ainsi à $J + 1$ problèmes indépendants, ce que nous traitons dans les sous-sections suivantes.

Méthode des multiplicateurs de Lagrange La méthode des multiplicateurs de Lagrange permet de ramener un problème d'optimisation sous contrainte à un problème d'optimisation sans contrainte. Pour maximiser une fonction $f(x)$ sous une contrainte de la forme $g(x) = 0$, on introduit une variable auxiliaire $\lambda \in \mathbb{R}$, appelée *multiplicateur de Lagrange*, et l'on forme

le Lagrangien

$$\Lambda(x, \lambda) = f(x) + \lambda g(x).$$

Les points critiques de Λ , obtenus en annulant simultanément ses dérivées partielles par rapport à x et à λ , fournissent les candidats à l'optimum sous contrainte.

2.1 Estimation de $\alpha^{(j)}$

on ne garde que la partie qui dépend de α :

$$\ell(\alpha) = \sum_{j=1}^J C_j \log \alpha(j)$$

avec la contrainte :

$$\sum_{j=1}^J \alpha(j) = 1.$$

Pour traiter ce problème de maximisation sous contrainte, on a recours à la méthode des multiplicateurs de Lagrange. On introduit un multiplicateur $\lambda \in \mathbb{R}$ associé à la contrainte $\sum_{j=1}^J \alpha(j) = 1$, et l'on définit le *Lagrangien* du problème par

$$\Lambda(\alpha, \lambda) = \sum_{j=1}^J C_j \log \alpha(j) + \lambda \left(1 - \sum_{j=1}^J \alpha(j) \right).$$

Le premier terme correspond à la fonction à maximiser, tandis que le second terme s'annule dès que la contrainte est vérifiée. Maximiser $\ell(\alpha)$ sous contrainte revient alors à rechercher un point critique de Λ , c'est-à-dire un point en lequel toutes les dérivées partielles de Λ s'annulent simultanément. Pour tout j ,

$$\frac{\partial \Lambda}{\partial \alpha(j)} = \frac{C_j}{\alpha(j)} - \lambda = 0 \quad \Longleftrightarrow \quad \alpha(j) = \frac{C_j}{\lambda}.$$

En imposant la contrainte $\sum_{j=1}^J \alpha(j) = 1$ et en remplaçant $\alpha(j)$ par son expression, on obtient

$$\sum_{j=1}^J \frac{C_j}{\lambda} = 1 \quad \Longleftrightarrow \quad \frac{1}{\lambda} \sum_{j=1}^J C_j = 1.$$

Or $\sum_{j=1}^J C_j = n$, puisque C_j compte le nombre d'observations vérifiant $Z_i = j$. Il vient alors

$$\frac{n}{\lambda} = 1 \quad \Longleftrightarrow \quad \lambda = n,$$

et l'on obtient finalement

$$\hat{\alpha}(j) = \frac{C_j}{n}.$$

La contrainte $\hat{\alpha}(j) > 0$ est automatiquement satisfaite : en effet, $C_j \geq 1$ dès que l'espèce j est représentée dans l'échantillon (ce qui est garanti par l'hypothèse que le problème est bien posé).

Deuxième partie

On part de la partie de la log-vraisemblance qui dépend de m et v :

$$L(\theta, \bar{X}, \bar{Z}) = \sum_{j=1}^J \sum_{i \in A_j} \log \gamma_{m(j), v(j)}(X_i) + C(\alpha),$$

où $C(\alpha)$ regroupe les termes ne dépendant que des proportions α , sans influence sur la maximisation en (m, v) .

or $\gamma_{m,v}$ est une densité normale

$$\gamma_{m(j), v(j)}(x) = \frac{1}{\sqrt{2\pi v(j)}} \exp \left(-\frac{(x - m(j))^2}{2v(j)} \right).$$

Alors pour une classe j , la contribution est :

$$\ell_j(m(j), v(j)) = \sum_{i \in A_j} \left[-\frac{1}{2} \log(2\pi v(j)) - \frac{(X_i - m(j))^2}{2v(j)} \right].$$

2.2 Estimation de $m^{(j)}$

On dérive par rapport à $m(j)$:

$$\frac{\partial \ell_j}{\partial m(j)} = \sum_{i \in A_j} \frac{X_i - m(j)}{v(j)} = \frac{1}{v(j)} \left(\sum_{i \in A_j} X_i - C_j m(j) \right).$$

On annule :

$$\sum_{i \in A_j} X_i - C_j m(j) = 0 \quad \Rightarrow \quad m(j) = \frac{1}{C_j} \sum_{i \in A_j} X_i.$$

La condition du premier ordre ne fournit qu'un candidat à l'optimum ; il reste à vérifier qu'il s'agit bien d'un maximum en examinant le signe de la dérivée seconde :

$$\ell_j''(m) = -\frac{1}{v(j)} \sum_{i \in A_j} 1 = -\frac{C_j}{v(j)}.$$

Comme $v(j) > 0$ et $C_j \geq 1$, on a $\ell_j''(m) < 0$, donc ℓ_j est strictement concave en m et le point critique trouvé est l'unique maximum global.

Donc l'estimateur de maximum de vraisemblance est :

$$\hat{m}(j) = \frac{1}{C_j} \sum_{i \in A_j} X_i.$$

2.3 Estimation de $v^{(j)}$

Écrivons

$$S_j = \sum_{i \in A_j} (X_i - m(j))^2.$$

Alors :

$$\ell_j = -\frac{C_j}{2} \log(2\pi v(j)) - \frac{1}{2v(j)} S_j.$$

en passant à la dérivée :

$$\frac{\partial \ell_j}{\partial v(j)} = -\frac{C_j}{2} \cdot \frac{1}{v(j)} + \frac{1}{2} \cdot \frac{S_j}{v(j)^2}.$$

Résolution :

$$-\frac{C_j}{2v(j)} + \frac{S_j}{2v(j)^2} = 0 \iff -C_j v(j) + S_j = 0 \iff v(j) = \frac{S_j}{C_j} = \frac{1}{C_j} \sum_{i \in A_j} (X_i - \hat{m}(j))^2.$$

La condition du premier ordre ne fournit qu'un candidat à l'optimum ; il reste à vérifier qu'il s'agit bien d'un maximum global sur $(0, +\infty)$ en étudiant le signe de la dérivée.

Étude du signe de la dérivée. On a

$$g'(v) = \frac{-C_j v + S_j}{2v^2}.$$

Comme $2v^2 > 0$, le signe de $g'(v)$ est celui du numérateur $-C_j v + S_j$. En pratique, $S_j > 0$ (le cas $S_j = 0$ correspondrait à une classe où toutes les observations seraient identiques, ce qui ne se produit pas sur des données réelles). Sous cette hypothèse, $g'(v)$ s'annule en

$$v(j) = \frac{S_j}{C_j},$$

et l'on vérifie aisément que

$$g'(v) > 0 \text{ si } 0 < v < v(j), \quad g'(v) < 0 \text{ si } v > v(j).$$

Ainsi, la fonction g est croissante sur $(0, v(j))$ puis décroissante sur $(v(j), +\infty)$, donc $v(j)$ est un maximum global. L'estimateur du maximum de vraisemblance est ainsi

$$\hat{v}(j) = \frac{1}{C_j} \sum_{i \in A_j} (X_i - \hat{m}(j))^2.$$

2.4 Limite du modèle complet et introduction de la vraisemblance observée

Le résultat précédent repose sur une hypothèse favorable mais irréaliste : on suppose que les variables latentes $Z_1, \dots, Z_n$ sont observées. Dans ce cas, les données peuvent être séparées par espèce et l'estimation des paramètres se fait simplement en maximisant la log-vraisemblance complète.

Cependant, en pratique, seules les tailles des nids $X_1, \dots, X_n$ sont observées. Les variables Z_i , qui indiquent l'espèce d'origine de chaque nid, restent inconnues. Il convient donc d'étudier la log-vraisemblance des observations seules, appelée log-vraisemblance observée, définie par :

$$L_{\text{obs}}(\theta, \bar{X}) = \sum_{i=1}^n \log \left(\sum_{j=1}^J \alpha(j) \gamma_{m(j), v(j)}(X_i) \right). \quad (5)$$

Contrairement au cas complet, le logarithme porte ici sur une somme. Cette structure empêche

de séparer les contributions des différentes composantes du mélange et rend la maximisation analytique difficile.

C'est précisément cette difficulté qui justifie l'introduction de l'algorithme EM, lequel permet d'approcher numériquement le maximum de vraisemblance en tenant compte du caractère latent des variables Z_i .

3 Résolution du vrai problème

Dans le cadre du mélange gaussien, on observe uniquement les tailles $X_1, \dots, X_n$ des nids, tandis que l'espèce ayant construit chaque nid est représentée par une variable latente $Z_i \in \{1, \dots, J\}$ qui n'est pas observée. Or, si les Z_i étaient connus, on pourrait écrire la log-vraisemblance complète sous une forme simple, en sommant les contributions de chaque paire (X_i, Z_i) . Le vrai problème vient donc du caractère partiellement observé du modèle : la maximisation directe de la vraisemblance des seules observations $X_1, \dots, X_n$ conduit à manipuler des expressions du type

$$\log \left(\sum_j \alpha(j) \gamma_{m(j), v(j)}(X_i) \right),$$

c'est-à-dire un logarithme d'une somme, qui est difficile à optimiser analytiquement. L'idée centrale de l'algorithme EM est alors de remplacer la log-vraisemblance complète, inaccessible parce qu'elle dépend de $\bar{Z}$, par sa moyenne conditionnelle sachant les observations $\bar{X}$. Plus précisément, étant donné un paramètre courant $\tilde{\theta}$ (issu de l'itération précédente), on définit la quantité

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \mathbb{E}_{\tilde{\theta}}(L(\theta, \bar{X}, \bar{Z}) \mid \bar{X}),$$

qui correspond à l'espérance conditionnelle de la log-vraisemblance.

Par définition, la densité jointe d'une observation complète (X_i, Z_i) au point (x, j) est notée $h_\theta(x, j)$. Dans un mélange gaussien, d'après (2), on a $h_\theta(x, j) = \alpha(j) \gamma_{m(j), v(j)}(x)$. Pour l'échantillon complet $(\bar{X}, \bar{Z})$, l'indépendance (conditionnelle) des observations donne :

$$p_\theta(\bar{X}, \bar{Z}) = \prod_{i=1}^n h_\theta(X_i, Z_i).$$

Donc, d'après (4), la log-vraisemblance complète est :

$$L(\theta, \bar{X}, \bar{Z}) = \log p_\theta(\bar{X}, \bar{Z}) = \sum_{i=1}^n \log h_\theta(X_i, Z_i).$$

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \mathbb{E}_{\tilde{\theta}}(L(\theta, \bar{X}, \bar{Z}) \mid \bar{X}).$$

En remplaçant L par son expression :

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \mathbb{E}_{\tilde{\theta}} \left(\sum_{i=1}^n \log h_\theta(X_i, Z_i) \mid \bar{X} \right).$$

Par linéarité,

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \sum_{i=1}^n \mathbb{E}_{\tilde{\theta}}(\log h_\theta(X_i, Z_i) \mid \bar{X}).$$

Dans ce modèle, sachant $\bar{X}$, chaque Z_i ne dépend que de X_i (structure i.i.d. du mélange), d'où :

$$\mathbb{E}_{\tilde{\theta}}(\log h_{\theta}(X_i, Z_i) \mid \bar{X}) = \mathbb{E}_{\tilde{\theta}}(\log h_{\theta}(X_i, Z_i) \mid X_i).$$

Ainsi,

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \sum_{i=1}^n \mathbb{E}_{\tilde{\theta}}(\log h_{\theta}(X_i, Z_i) \mid X_i).$$

Conditionnellement à X_i , la variable Z_i est discrète et prend les valeurs $1, \dots, J$. Pour toute fonction φ ,

$$\mathbb{E}_{\tilde{\theta}}(\varphi(Z_i) \mid X_i) = \sum_{j=1}^J \varphi(j) \mathbb{P}_{\tilde{\theta}}(Z_i = j \mid X_i).$$

On applique ceci à la fonction $\varphi(j) = \log h_{\theta}(X_i, j)$. On obtient :

$$\mathbb{E}_{\tilde{\theta}}(\log h_{\theta}(X_i, Z_i) \mid X_i) = \sum_{j=1}^J \log h_{\theta}(X_i, j) \mathbb{P}_{\tilde{\theta}}(Z_i = j \mid X_i).$$

En notant

$$g_{\tilde{\theta}}(j \mid X = X_i) = \mathbb{P}_{\tilde{\theta}}(Z_i = j \mid X_i),$$

on arrive à :

$$\mathbb{E}_{\tilde{\theta}}(\log h_{\theta}(X_i, Z_i) \mid X_i) = \sum_{j=1}^J \log h_{\theta}(X_i, j) g_{\tilde{\theta}}(j \mid X = X_i).$$

En réinjectant dans la somme sur i ,

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \sum_{i=1}^n \sum_{j=1}^J \log h_{\theta}(X_i, j) g_{\tilde{\theta}}(j \mid X = X_i).$$

Maximiser L_{obs} directement est hors d'atteinte, on passe donc par $L_c(\theta, \tilde{\theta}, \bar{X})$. L'idée est simple, on commence par l'écrire explicitement dans le cas gaussien, puis on cherche son maximum en θ . Ce maximum donnera la mise à jour θ_{k+1} , et c'est ce qui assurera la croissance de L_{obs} d'une itération à l'autre.

Théorème (Log-vraisemblance conditionnelle)

Dans le cadre du modèle de mélange gaussien, la log-vraisemblance conditionnelle introduite précédemment s'écrit

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \mathbb{E}_{\tilde{\theta}}(L(\theta, \bar{X}, \bar{Z}) \mid \bar{X}).$$

En utilisant l'équation (2) et le développement explicite de $\gamma_{m(j), v(j)}$, on rappelle que

$$h_{\theta}(x, j) = \alpha(j) \frac{1}{\sqrt{2\pi v(j)}} \exp\left(-\frac{(x - m(j))^2}{2v(j)}\right).$$

En prenant le logarithme, on obtient

$$\log h_\theta(x, j) = \log \alpha(j) - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log v(j) - \frac{(x - m(j))^2}{2v(j)}.$$

On remplace alors $\log h_\theta(X_i, j)$ dans L_c :

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \sum_{i=1}^n \sum_{j=1}^J g_{\tilde{\theta}}(j | X = X_i) \left[\log \alpha(j) - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log v(j) - \frac{(X_i - m(j))^2}{2v(j)} \right].$$

On développe la somme terme à terme. on obtient :

$$\begin{aligned} L_c(\theta, \tilde{\theta}, \bar{X}) &= -\frac{n}{2} \log(2\pi) + \sum_{j=1}^J \left(\sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) \right) \log \alpha(j) \\ &\quad - \frac{1}{2} \sum_{j=1}^J \left(\sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) \right) \log v(j) \\ &\quad - \frac{1}{2} \sum_{j=1}^J \sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) \frac{(X_i - m(j))^2}{v(j)}. \end{aligned}$$

Théorème (Maximum de la log-vraisemblance conditionnelle)

Estimer $\alpha(j)$:

Dans L_c , les termes contenant $\alpha(j)$ sont :

$$\sum_{j=1}^J \left(\sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) \right) \log \alpha(j).$$

Les autres termes ne dépendent pas de $\alpha(j)$.

On pose

$$u_j = \sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i).$$

La fonction à maximiser par rapport à $\alpha(1), \dots, \alpha(J)$ est :

$$\sum_{j=1}^J u_j \log \alpha(j), \quad \text{sous contrainte} \quad \sum_{j=1}^J \alpha(j) = 1.$$

C'est un problème d'optimisation sous contrainte, que l'on résout par la méthode du multiplicateur de Lagrange déjà introduite précédemment.

Soit le Lagrangien :

$$\Lambda = \sum_{j=1}^J u_j \log \alpha(j) + \lambda \left(1 - \sum_{j=1}^J \alpha(j) \right).$$

On dérive par rapport à chaque $\alpha(j)$.

$$\frac{\partial}{\partial \alpha(j)} (u_j \log \alpha(j)) = \frac{u_j}{\alpha(j)}.$$

$$\frac{\partial}{\partial \alpha(j)} \left(-\lambda \sum_{k=1}^J \alpha(k) \right) = -\lambda.$$

Donc

$$\frac{\partial \Lambda}{\partial \alpha(j)} = \frac{u_j}{\alpha(j)} - \lambda.$$

La condition d'optimalité $\frac{\partial \Lambda}{\partial \alpha(j)} = 0$ donne

$$\frac{u_j}{\alpha(j)} = \lambda \quad \Leftrightarrow \quad \alpha(j) = \frac{u_j}{\lambda}.$$

En substituant dans la contrainte $\sum_{j=1}^J \alpha(j) = 1$:

$$\frac{1}{\lambda} \sum_{j=1}^J u_j = 1.$$

Or, les deux sommes étant finies, on peut intervertir leur ordre :

$$\sum_{j=1}^J u_j = \sum_{i=1}^n \sum_{j=1}^J g_{\tilde{\theta}}(j \mid X_i) = n,$$

puisque $\sum_{j=1}^J g_{\tilde{\theta}}(j \mid X_i) = 1$ pour tout i . On obtient donc $\lambda = n$, et finalement

$$\alpha(j) = \frac{u_j}{n}.$$

Notons que la contrainte $\alpha(j) > 0$ n'a pas été traitée explicitement dans le Lagrangien ; il convient donc de vérifier que la solution obtenue la satisfait bien. Or, $g_{\tilde{\theta}}(j \mid X_i) > 0$ pour tout i , donc $u_j = \sum_{i=1}^n g_{\tilde{\theta}}(j \mid X_i) > 0$, et ainsi $\alpha(j) = u_j/n > 0$.

$$u_j = \sum_{i=1}^n g_{\tilde{\theta}}(j \mid X_i).$$

Donc :

$$\alpha(j) = \frac{1}{n} \sum_{i=1}^n g_{\tilde{\theta}}(j \mid X_i).$$

Estimation de $m(j)$

On fixe $j \in \{1, \dots, J\}$ et on pose, pour alléger l'écriture,

$$w_{ij} = g_{\tilde{\theta}}(j \mid X = X_i) \quad (i = 1, \dots, n),$$

Dans L_c , la seule dépendance en $m(j)$ est dans le terme

$$-\frac{1}{2} \sum_{i=1}^n w_{ij} \frac{(X_i - m(j))^2}{v(j)}.$$

Donc, maximiser L_c en $m(j)$ revient à maximiser

$$\ell_j(m(j)) = -\frac{1}{2v(j)} \sum_{i=1}^n w_{ij} (X_i - m(j))^2.$$

On dérive :

$$\frac{d}{dm(j)} (X_i - m(j))^2 = 2(X_i - m(j)) \cdot \frac{d}{dm(j)} (X_i - m(j)) = 2(X_i - m(j)) \cdot (-1) = -2(X_i - m(j)).$$

Ainsi,

$$\ell'_j(m(j)) = -\frac{1}{2v(j)} \sum_{i=1}^n w_{ij} (-2(X_i - m(j))) = \frac{1}{v(j)} \sum_{i=1}^n w_{ij} (X_i - m(j)).$$

Condition du point critique $\ell'_j(m(j)) = 0$:

$$\sum_{i=1}^n w_{ij} (X_i - m(j)) = 0 \iff \sum_{i=1}^n w_{ij} X_i - m(j) \sum_{i=1}^n w_{ij} = 0.$$

Donc

$$m(j) = \frac{\sum_{i=1}^n X_i w_{ij}}{\sum_{i=1}^n w_{ij}} = \frac{\sum_{i=1}^n X_i g_{\hat{\theta}}(j | X = X_i)}{\sum_{i=1}^n g_{\hat{\theta}}(j | X = X_i)}.$$

C'est exactement

$$\hat{m}(j) = \frac{\sum_{i=1}^n X_i g_{\hat{\theta}}(j | X = X_i)}{\sum_{i=1}^n g_{\hat{\theta}}(j | X = X_i)}.$$

$$\ell''_j(m(j)) = \frac{1}{v(j)} \sum_{i=1}^n w_{ij} \frac{d}{dm(j)} (X_i - m(j)) = \frac{1}{v(j)} \sum_{i=1}^n w_{ij} (-1) = -\frac{1}{v(j)} \sum_{i=1}^n w_{ij} < 0.$$

(car $v(j) > 0$ et $w_{ij} \geq 0$, et en pratique $\sum_i w_{ij} > 0$.)

Donc ℓ_j est concave en $m(j)$ et ce point critique est le maximum global.

Estimation de $v(j)$

Dans L_c , les termes qui dépendent de $v(j)$ sont :

$$-\frac{1}{2} \sum_{i=1}^n w_{ij} \left(\log v(j) + \frac{(X_i - m(j))^2}{v(j)} \right).$$

Donc on maximise, pour $v = v(j)$,

$$\ell_j(v) = -\frac{1}{2} \sum_{i=1}^n w_{ij} \left(\log v + \frac{(X_i - m(j))^2}{v} \right), \quad v > 0.$$

Posons

$$n_j = \sum_{i=1}^n w_{ij}, \quad T_j = \sum_{i=1}^n w_{ij} (X_i - m(j))^2.$$

Alors

$$\ell_j(v) = -\frac{1}{2} \left(n_j \log v + \frac{T_j}{v} \right).$$

On dérive :

$$\ell'_j(v) = -\frac{1}{2} \left(\frac{n_j}{v} - \frac{T_j}{v^2} \right).$$

Condition du point critique $\ell'_j(v) = 0$:

$$\frac{n_j}{v} - \frac{T_j}{v^2} = 0 \quad \Longleftrightarrow \quad n_j v - T_j = 0 \quad \Longleftrightarrow \quad v = \frac{T_j}{n_j}.$$

En réinjectant T_j et n_j :

$$v(j) = \frac{\sum_{i=1}^n w_{ij} (X_i - m(j))^2}{\sum_{i=1}^n w_{ij}} = \frac{\sum_{i=1}^n (X_i - m(j))^2 g_{\hat{\theta}}(j | X = X_i)}{\sum_{i=1}^n g_{\hat{\theta}}(j | X = X_i)}.$$

Donc, en prenant $m(j) = \hat{m}(j)$,

$$\hat{v}(j) = \frac{\sum_{i=1}^n (X_i - \hat{m}(j))^2 g_{\hat{\theta}}(j | X = X_i)}{\sum_{i=1}^n g_{\hat{\theta}}(j | X = X_i)}.$$

$$\ell''_j(v) = -\frac{1}{2} \left(-\frac{n_j}{v^2} + \frac{2T_j}{v^3} \right) = \frac{1}{2} \left(\frac{n_j}{v^2} - \frac{2T_j}{v^3} \right).$$

Au point $v = \frac{T_j}{n_j}$:

$$\ell''_j \left(\frac{T_j}{n_j} \right) = \frac{1}{2} \left(\frac{n_j}{(T_j/n_j)^2} - \frac{2T_j}{(T_j/n_j)^3} \right) = \frac{1}{2} \left(\frac{n_j^3}{T_j^2} - \frac{2n_j^3}{T_j^2} \right) = -\frac{1}{2} \frac{n_j^3}{T_j^2} < 0,$$

donc c'est bien un maximum local. De plus, ℓ_j étant strictement concave sur $v > 0$ (car $\ell''_j < 0$ en tout point), ce maximum local est en fait un maximum global sur $(0, +\infty)$. On peut donc conclure que le maximiseur unique de ℓ_j est

$$\hat{v}(j) = \frac{T_j}{n_j},$$

ce qui constitue la mise à jour de l'étape M pour la variance de la j -ième composante.

Théorème Croissance de la vraisemblance observée

On considère la suite $(\theta_k)_{k \geq 0}$ construite par l'algorithme EM. Le théorème affirme que cette suite vérifie la propriété de croissance suivante :

$$L_{\text{obs}}(\theta_{k+1}, \bar{X}) \geq L_{\text{obs}}(\theta_k, \bar{X}),$$

où $L_{\text{obs}}(\theta, \bar{X})$ désigne la log-vraisemblance des observations définie en (5).

Autrement dit, la vraisemblance observée est monotone croissante le long des itérations de l'algorithme.

Démonstration. On introduit la quantité :

$$H(\theta, \theta_k) = \mathbb{E}_{\theta_k}(\log g_{\theta}(\bar{Z} \mid \bar{X})).$$

En développant :

$$H(\theta, \theta_k) = \sum_{i=1}^n \mathbb{E}_{\theta_k}(\log g_{\theta}(Z_i \mid X_i)).$$

Cette quantité correspond à une moyenne du logarithme des probabilités conditionnelles des variables latentes.

On utilise la relation :

$$h_{\theta}(x, z) = f_{\theta}(x) g_{\theta}(z \mid x),$$

En prenant le logarithme :

$$\log h_{\theta}(x, z) = \log f_{\theta}(x) + \log g_{\theta}(z \mid x).$$

En prenant l'espérance conditionnelle sous θ_k , on obtient :

$$L_c(\theta, \theta_k, \bar{X}) = L_{\text{obs}}(\theta, \bar{X}) + H(\theta, \theta_k). \quad (6)$$

Par définition de l'étape M :

$$L_c(\theta_{k+1}, \theta_k, \bar{X}) \geq L_c(\theta_k, \theta_k, \bar{X}).$$

Or, la décomposition (6) est valable pour tout $\theta \in \Theta$ (pas seulement pour $\theta = \theta_k$). En l'appliquant successivement à $\theta = \theta_{k+1}$ puis à $\theta = \theta_k$, on obtient :

$$\begin{aligned} L_c(\theta_{k+1}, \theta_k, \bar{X}) &= L_{\text{obs}}(\theta_{k+1}, \bar{X}) + H(\theta_{k+1}, \theta_k), \\ L_c(\theta_k, \theta_k, \bar{X}) &= L_{\text{obs}}(\theta_k, \bar{X}) + H(\theta_k, \theta_k). \end{aligned}$$

On remplace dans l'inégalité précédente :

$$L_{\text{obs}}(\theta_{k+1}) + H(\theta_{k+1}, \theta_k) \geq L_{\text{obs}}(\theta_k) + H(\theta_k, \theta_k).$$

On réarrange :

$$L_{\text{obs}}(\theta_{k+1}) - L_{\text{obs}}(\theta_k) \geq H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k).$$

Par définition :

$$H(\theta, \theta_k) = \mathbb{E}_{\theta_k}(\log g_{\theta}(\bar{Z} \mid \bar{X})).$$

Donc :

$$H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k) = \mathbb{E}_{\theta_k} \left[\log \frac{g_{\theta_k}(\bar{Z} \mid \bar{X})}{g_{\theta_{k+1}}(\bar{Z} \mid \bar{X})} \right].$$

On note μ_{θ_k} la loi de $\bar{Z} \mid \bar{X}$ sous P_{θ_k} .

Alors l'expression devient :

$$\int \log \frac{d\mu_{\theta_k}}{d\mu_{\theta_{k+1}}} d\mu_{\theta_k}.$$

Entropie relative (Kullback-Leibler)

L'entropie relative, ou divergence de Kullback–Leibler, est une mesure qui quantifie la différence entre deux distributions de probabilité P et Q . Elle mesure la perte d'information subie lorsqu'on utilise la loi Q pour approximer la loi vraie P . Elle est toujours positive et s'annule si et seulement si $P = Q$ presque partout.

Mais cela correspond exactement à :

$$D(\mu_{\theta_k} \parallel \mu_{\theta_{k+1}}),$$

c'est-à-dire l'entropie relative. La divergence de Kullback-Leibler vérifie toujours :

$$D(P \parallel Q) \geq 0.$$

Cela vient de l'inégalité de Jensen, que nous rappelons brièvement.

Inégalité de Jensen

Soit $\varphi : I \rightarrow \mathbb{R}$ une fonction convexe sur un intervalle $I \subset \mathbb{R}$, et soit Y une variable aléatoire intégrable à valeurs dans I . Alors

$$\varphi(\mathbb{E}[Y]) \leq \mathbb{E}[\varphi(Y)].$$

Si φ est concave, l'inégalité est inversée.

En appliquant ce résultat à la fonction concave $\log$ et à la variable $Y = \frac{g_{\theta_{k+1}}(Z \mid X)}{g_{\theta_k}(Z \mid X)}$ sous $\mathbb{P}_{\theta_k}$, on obtient :

$$\mathbb{E}_{\theta_k} \left[\log \frac{g_{\theta_{k+1}}(Z \mid X)}{g_{\theta_k}(Z \mid X)} \right] \leq \log \mathbb{E}_{\theta_k} \left[\frac{g_{\theta_{k+1}}(Z \mid X)}{g_{\theta_k}(Z \mid X)} \right] = \log 1 = 0,$$

d'où $D(\mu_{\theta_k} \parallel \mu_{\theta_{k+1}}) \geq 0$.

Donc :

$$H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k) \geq 0.$$

On revient à :

$$L_{\text{obs}}(\theta_{k+1}) - L_{\text{obs}}(\theta_k) \geq H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k).$$

Comme le terme de droite est positif, on obtient :

$$L_{\text{obs}}(\theta_{k+1}) \geq L_{\text{obs}}(\theta_k).$$

□

Ce théorème montre que la suite des log-vraisemblances observées

$$\left(L_{\text{obs}}(\theta_k, \bar{X}) \right)_{k \geq 0}$$

est croissante au fil des itérations de l'algorithme EM. Autrement dit, à chaque étape, la vraisemblance des données observées augmente ou reste constante. Comme cette suite est également majorée, elle converge vers une limite $L^* \in \mathbb{R}$. Cette propriété assure un comportement régulier de l'algorithme, la log-vraisemblance évolue de manière monotone, sans osciller ni diminuer d'une itération à l'autre.

En revanche, ce résultat ne dit rien, en l'état, sur le comportement de la suite des paramètres $(\theta_k)_{k \geq 0}$ elle-même. Même si les valeurs $L_{\text{obs}}(\theta_k)$ se stabilisent, la suite des paramètres pourrait ne pas converger, et si elle converge, sa limite n'est pas nécessairement un point critique de L_{obs} , encore moins un maximum global. En présence de variables latentes, la fonction de vraisemblance observée peut admettre plusieurs maxima locaux, et l'algorithme EM peut converger vers l'un d'eux, ce qui rend le résultat final dépendant du choix des paramètres initiaux. Une mauvaise initialisation peut ainsi conduire à une solution sous-optimale. Pour limiter cette sensibilité, on peut lancer l'algorithme plusieurs fois avec des points de départ différents ou introduire une composante aléatoire dans la procédure, par exemple à l'aide de techniques inspirées du recuit simulé. Néanmoins, ces approches n'offrent aucune garantie d'atteindre le maximum global.

Enfin, il n'existe pas de règle théorique précise permettant de déterminer à l'avance le nombre d'itérations nécessaires pour approcher suffisamment un maximum local. En pratique, on s'appuie sur des critères d'arrêt empiriques, tels que la stabilisation de la log-vraisemblance ou la faible variation des paramètres, sans qu'il n'existe de critère universellement optimal.

Limites du résultat de monotonie

Comme on l'a souligné plus haut, la monotonie de la log-vraisemblance observée ne porte que sur ses valeurs et ne garantit ni la convergence de la suite des paramètres $(\theta_k)_{k \geq 0}$, ni que sa limite éventuelle soit un point stationnaire de L_{obs} . Pour répondre à ces questions, il est nécessaire de faire appel à des résultats complémentaires, établis par Dempster, Laird et Rubin (1977) puis précisés par Wu (1983), qui fournissent des conditions suffisantes sous lesquelles la convergence de la suite des paramètres peut être garantie.

Convergence vers un point stationnaire (Dempster, Laird et Rubin, 1977)

Dans leur article fondateur, Dempster, Laird et Rubin établissent le résultat conditionnel suivant :

Dans cette section, la fonction Q désigne l'espérance conditionnelle complète introduite en partie 3, c'est-à-dire $Q(\theta | \tilde{\theta}, X) := L_c(\theta, \tilde{\theta}, \bar{X})$.

Théorème 1. *Supposons que la suite $(\theta_k)_{k \geq 0}$ produite par l'algorithme EM converge vers un point $\theta^* \in \text{int}(\Theta)$. Supposons de plus que :*

- *la fonction $Q(\cdot | \tilde{\theta})$ est continue en $(\theta, \tilde{\theta})$;*
- *la log-vraisemblance observée $L_{\text{obs}}(\theta, X)$ est dérivable en θ^* .*

Alors θ^ est un point stationnaire de L_{obs} , c'est-à-dire*

$$\nabla_{\theta} L_{\text{obs}}(\theta^*, X) = 0.$$

Démonstration. Par définition de l'étape M, on a pour tout $k \geq 0$:

$$Q(\theta_{k+1} | \theta_k, X) \geq Q(\theta | \theta_k, X) \quad \text{pour tout } \theta \in \Theta.$$

En particulier, θ_{k+1} maximise $Q(\cdot | \theta_k, X)$, donc si θ_{k+1} est intérieur à Θ , la condition nécessaire du premier ordre donne :

$$\nabla_{\theta} Q(\theta_{k+1} | \theta_k, X) = 0.$$

Or, d'après la décomposition (6), la log-vraisemblance observée s'écrit également :

$$L_{\text{obs}}(\theta, X) = L_c(\theta, \tilde{\theta}, X) - H(\theta, \tilde{\theta}),$$

où $H(\theta, \tilde{\theta}) = E_{\tilde{\theta}}[\log g_{\theta}(Z | X)]$. En dérivant cette relation par rapport à θ et en évaluant en $\theta = \tilde{\theta}$, on obtient :

$$\nabla_{\theta} L_{\text{obs}}(\theta, X) = \nabla_{\theta} Q(\theta | \tilde{\theta}, X) - \nabla_{\theta} H(\theta, \tilde{\theta}).$$

On calcule explicitement ce gradient. D'abord,

$$\nabla_{\theta} H(\theta, \tilde{\theta}) = E_{\tilde{\theta}}[\nabla_{\theta} \log g_{\theta}(Z | X)] = E_{\tilde{\theta}}\left[\frac{\nabla_{\theta} g_{\theta}(Z | X)}{g_{\theta}(Z | X)}\right].$$

En évaluant en $\theta = \tilde{\theta}$ et en utilisant le fait que $\sum_j g_{\theta}(j | X_i) = 1$ pour tout θ , on obtient $\nabla_{\theta} \sum_j g_{\theta}(j | X_i) = 0$, ce qui donne :

$$\nabla_{\theta} H(\theta, \tilde{\theta})\big|_{\theta=\tilde{\theta}} = 0.$$

Il en résulte que :

$$\nabla_{\theta} L_{\text{obs}}(\theta, X)\big|_{\theta=\tilde{\theta}} = \nabla_{\theta} Q(\theta | \tilde{\theta}, X)\big|_{\theta=\tilde{\theta}}.$$

Si $(\theta_k) \rightarrow \theta^*$, alors $\theta_{k+1} \rightarrow \theta^*$ et $\theta_k \rightarrow \theta^*$. Par passage à la limite dans l'égalité $\nabla_{\theta} Q(\theta_{k+1} | \theta_k, X) = 0$ et par continuité, on obtient :

$$\nabla_{\theta} Q(\theta^* | \theta^*, X) = 0,$$

et donc, grâce à la relation ci-dessus :

$$\nabla_{\theta} L_{\text{obs}}(\theta^*, X) = 0.$$

□

Ce résultat est fondamental : il assure que si l'algorithme EM converge, sa limite est nécessairement un point stationnaire de la vraisemblance observée. Cependant, l'hypothèse de départ — « supposons que (θ_k) converge » — n'est pas démontrée. Autrement dit, Dempster, Laird et Rubin montrent *où* l'algorithme converge, mais pas *qu'il* converge. C'est précisément cette lacune que Wu (1983) a cherché à combler.

Conditions suffisantes de convergence (Wu, 1983)

Wu [1] a complété l'analyse de Dempster, Laird et Rubin en étudiant rigoureusement les deux questions restées ouvertes :

1. La suite des paramètres $(\theta_k)_{k \geq 0}$ converge-t-elle ?
2. Si oui, la limite est-elle un maximum local, ou simplement un point stationnaire (éventuellement un point selle ou un minimum local) de la vraisemblance observée ?

Pour y répondre, Wu s'appuie sur le **théorème de convergence globale de Zangwill** (1969), un résultat d'optimisation portant sur les applications *point-à-ensemble* (*point-to-set maps*). L'idée est de considérer l'algorithme EM comme une application $M : \Theta \rightarrow \Theta$ définie par :

$$\theta_{k+1} = M(\theta_k), \quad \text{où} \quad M(\tilde{\theta}) = \arg \max_{\theta \in \Theta} Q(\theta | \tilde{\theta}, X).$$

Le théorème de Zangwill garantit la convergence sous trois conditions :

- (Z1) Tous les itérés θ_k restent dans un ensemble **compact** $S \subset \Theta$;
- (Z2) L'application M est **fermée** en tout point de S qui n'est pas un point stationnaire de L_{obs} ;
- (Z3) La log-vraisemblance L_{obs} est une **fonction de descente** adaptée, c'est-à-dire que $L_{\text{obs}}(M(\theta)) > L_{\text{obs}}(\theta)$ pour tout θ qui n'est pas un point stationnaire.

La condition (Z3) est vérifiée grâce au théorème de croissance démontré précédemment (section 3), combiné au fait que l'égalité $L_{\text{obs}}(\theta_{k+1}) = L_{\text{obs}}(\theta_k)$ n'a lieu que si θ_k est déjà un point stationnaire. La condition (Z1) — la compacité — est l'hypothèse la plus importante. Elle est satisfaite dès que les ensembles de niveau

$$\Theta_{\theta_0} = \left\{ \theta \in \Theta : L_{\text{obs}}(\theta, X) \geq L_{\text{obs}}(\theta_0, X) \right\}$$

sont compacts. Comme la suite $(L_{\text{obs}}(\theta_k))$ est croissante, tous les itérés θ_k appartiennent à Θ_{θ_0} , qui est compact par hypothèse.

La condition (Z2) — la fermeture de M — est vérifiée dès que $Q(\cdot | \tilde{\theta}, X)$ admet un unique maximum global pour tout $\tilde{\theta}$, ce qui rend M continue.

Sous ces conditions, Wu établit les résultats suivants :

Théorème 2 (Wu, 1983 — Convergence des points limites). *Supposons que les conditions (Z1)–(Z3) sont satisfaites. Alors tous les points limites de la suite $(\theta_k)_{k \geq 0}$ sont des points stationnaires de la log-vraisemblance observée $L_{\text{obs}}(\cdot, X)$.*

Ce résultat est plus fort que celui de Dempster, Laird et Rubin : il ne *suppose* pas la convergence de (θ_k) , il montre que tout point d'accumulation de la suite est nécessairement un point stationnaire.

Théorème 3 (Wu, 1983 — Cas des familles exponentielles). *Si le modèle à données complètes appartient à une famille exponentielle courbe et que l'espace des paramètres Θ est compact, alors tous les points limites de toute suite EM sont des points stationnaires de L_{obs} .*

Ce cas s'applique en particulier aux **mélanges finis de lois gaussiennes**, qui constituent le cadre de notre étude, à condition de travailler sur un espace de paramètres borné (ce qui est raisonnable en pratique, les moyennes et variances étant bornées par les données observées).

Enfin, Wu souligne une mise en garde importante : le fait que l'étape M maximise *globalement* la fonction $Q(\cdot | \tilde{\theta}, X)$ à chaque itération a pu créer une fausse impression selon laquelle l'algorithme EM convergerait nécessairement vers le maximum *global* de L_{obs} . En réalité, dans le cas général où L_{obs} possède plusieurs maxima locaux, l'algorithme peut converger vers n'importe lequel d'entre eux, en fonction de l'initialisation θ_0 .

Synthèse et conséquences pratiques

En résumé, la convergence de l'algorithme EM repose sur trois niveaux de résultats, chacun apportant une garantie supplémentaire :

1. **Monotonie** (démontré dans ce rapport) : la suite des log-vraisemblances observées $(L_{\text{obs}}(\theta_k, X))_{k \geq 0}$ est croissante et majorée, donc convergente vers une valeur $L^* \in \mathbb{R}$. Ce résultat assure la stabilité numérique de l'algorithme, mais ne porte que sur les valeurs de la vraisemblance, pas sur les paramètres eux-mêmes.
2. **Caractérisation de la limite** (Dempster, Laird et Rubin, 1977) : si la suite des paramètres (θ_k) converge vers un point θ^* intérieur à Θ , alors θ^* est un point stationnaire de L_{obs} , c'est-à-dire $\nabla L_{\text{obs}}(\theta^*) = 0$.
3. **Existence de la convergence** (Wu, 1983) : sous des conditions de compacité de l'espace des paramètres et de régularité de la fonction Q , tout point d'accumulation de la suite (θ_k) est un point stationnaire de L_{obs} . Ce résultat s'applique en particulier aux mélanges finis de lois gaussiennes, dont le modèle complet (X, Z) appartient à une famille exponentielle, dès que l'espace des paramètres est restreint à un compact, ce qui est raisonnable en pratique.

Dans le cadre de notre modèle de mélange de J lois gaussiennes, le modèle complet (X, Z) appartient à une famille exponentielle. Les résultats de Wu s'appliquent donc dès que l'on restreint l'espace des paramètres à un compact, par exemple en imposant des bornes sur les moyennes, des bornes inférieures et supérieures sur les variances, et des bornes inférieures sur les proportions :

$$\Theta_0 = \left\{ \theta = \left(\alpha^{(j)}, m^{(j)}, v^{(j)} \right)_{1 \leq j \leq J} : \alpha^{(j)} \geq \varepsilon, \quad v_{\min} \leq v^{(j)} \leq v_{\max}, \quad |m^{(j)}| \leq M \right\},$$

avec $\varepsilon > 0$, $0 < v_{\min} < v_{\max}$ et $M > 0$ choisis de manière raisonnable au vu des données.

En pratique, ces contraintes sont naturellement satisfaites : les moyennes estimées restent dans la plage des données observées, et les variances ne dégénèrent pas vers zéro lorsque chaque composante est associée à un nombre suffisant d'observations.

4 Applications numériques

4.1 Données simulées

4.1.1 Validation sur données simulées

Afin de valider l'algorithme EM présenté dans la partie théorique, nous allons réaliser une application numérique sur des données simulées. Nous considérons un mélange de trois lois gaussiennes correspondant aux trois espèces de mouettes, avec des paramètres vrais fixés à :


$$\alpha = (0.4, 0.4, 0.2), \quad m = (-2, 0, 2), \quad v = (0.3, 0.2, 0.2)$$

et un échantillon de $n = 1000$ observations. L'objectif est de vérifier que l'algorithme EM, en partant de paramètres initiaux arbitraires, est capable de retrouver les vrais paramètres du mélange à partir des seules données observées.

```
1 #Convergence a l'iteration 45
2
3 #Espece 1 :
4 #  alpha   : estime = 0.386   / vrai = 0.4
5 #  mu      : estime = -2.027  / vrai = -2
6 #  var     : estime = 0.34    / vrai = 0.3
7
8 #Espece 2 :
9 #  alpha   : estime = 0.397   / vrai = 0.4
10 #  mu      : estime = 0.003   / vrai = 0
11 #  var     : estime = 0.213   / vrai = 0.2
12
13 #Espece 3 :
14 #  alpha   : estime = 0.217   / vrai = 0.2
15 #  mu      : estime = 2.001   / vrai = 2
16 #  var     : estime = 0.195   / vrai = 0.2
```

Les résultats obtenus après 45 itérations montrent que l'algorithme EM a bien convergé. En comparant les paramètres estimés aux paramètres vrais, on constate que les moyennes sont très bien retrouvées, avec des erreurs inférieures à 0.03 pour les trois espèces. Les proportions et les variances sont également bien estimées, avec de légères différences dues à la nature aléatoire de l'échantillon simulé.

Le graphique confirme visuellement ce résultat : les courbes estimées (trait plein) sont quasiment confondues avec les courbes vraies (pointillé) pour les trois espèces, ce qui valide le bon fonctionnement de l'algorithme EM sur ce modèle de mélange gaussien.



Validation par le test de Kolmogorov-Smirnov

```

1 # Asymptotic one-sample Kolmogorov-Smirnov test
2
3 #data:  X
4 #D = 0.010453, p-value = 0.9999
5 #alternative hypothesis: two-sided

```

Afin de valider l'ajustement du modèle estimé par l'algorithme EM, nous avons appliqué le test de Kolmogorov-Smirnov en comparant la fonction de répartition empirique des données simulées à la fonction de répartition théorique du mélange estimé, définie par :

$$F(x) = \sum_{j=1}^J \hat{\alpha}^{(j)} \Phi\left(\frac{x - \hat{m}^{(j)}}{\sqrt{\hat{v}^{(j)}}}\right)$$


où $\hat{\alpha}^{(j)}$, $\hat{m}^{(j)}$ et $\hat{v}^{(j)}$ désignent respectivement les poids, moyennes et variances estimés par l'algorithme EM, et Φ la fonction de répartition de la loi normale standard.

Le test fournit une statistique $D = 0,010453$ et une p -value de 0,9999. Une valeur de D aussi faible signifie que le mélange estimé reproduit très bien la distribution des données, et la p -value confirme qu'on n'a aucune raison de rejeter le modèle ajusté. Il faut toutefois noter que les paramètres ont été estimés sur les mêmes données que celles utilisées pour le test, ce qui rend la p -value légèrement optimiste. Malgré cette limite, le résultat reste une bonne confirmation de la convergence de l'algorithme EM.

Robustesse du test

Pour vérifier la stabilité du résultat, nous avons répété la procédure plusieurs fois en utilisant à chaque fois un échantillon de test différent de celui ayant servi à estimer les paramètres. Les p -values obtenues varient d'une répétition à l'autre, ce qui est attendu puisque chaque échantillon de test est généré indépendamment. Néanmoins, la majorité des p -values restent élevées, ce qui confirme que l'algorithme EM retrouve de manière fiable les vrais paramètres du mélange.

Vrai vs Estimé par EM — influence de la taille de l'échantillon



Ce graphique montre comment les trois courbes estimées évoluent au fil des itérations. Les vraies densités sont en pointillés rouges, et les estimations en bleu, de plus en plus foncé à chaque étape.

À l'itération 1, les courbes sont déjà bien centrées sur les bonnes moyennes $m = (-2, 0, 2)$. Par contre, elles sont trop larges et trop plates : les variances de départ sont trop grandes.

Au fil des itérations, les courbes se resserrent et leurs sommets remontent. Elles se rapprochent petit à petit des vraies densités. À partir de l'itération 30, on ne voit presque plus de changement.

À l'itération 45, l'algorithme s'arrête. Les courbes bleues recouvrent presque parfaitement les courbes rouges. L'algorithme a bien retrouvé le vrai modèle.


On voit ici, de manière visuelle, ce que dit le théorème de croissance : à chaque itération, l'estimation se rapproche du vrai modèle, sans jamais s'en éloigner.

4.1.2 Influence du nombre de composantes

Afin de tester le comportement de l'algorithme EM lorsque le nombre de composantes augmente, nous avons considéré un mélange de $J = 5$ lois gaussiennes avec les paramètres suivants :

$$\alpha = (0,25, 0,15, 0,25, 0,20, 0,15), \quad m = (-6, -3, 0, 3, 6), \quad v = (0,3, 0,4, 0,3, 0,2, 0,3)$$

et un échantillon de taille $n = 1000$. L'algorithme converge en seulement 20 itérations et retrouve fidèlement les vrais paramètres, avec des erreurs très faibles sur les moyennes (inférieures à 0,05), les proportions (inférieures à 0,02) et les variances (inférieures à 0,06). Le graphique confirme visuellement ce résultat : les courbes estimées se superposent quasi parfaitement aux courbes vraies pour les cinq composantes. Le test de Kolmogorov-Smirnov, appliqué sur un échantillon indépendant, donne une statistique $D = 0,021$ et une p -value de 0,75, ce qui confirme le bon ajustement du modèle. Ce résultat montre que l'algorithme EM reste performant lorsque le nombre de composantes augmente, à condition que celles-ci soient suffisamment séparées.




4.1.3 Comportement face à des composantes proches

Pour évaluer le comportement de l'algorithme EM lorsque les composantes du mélange sont peu séparées, nous avons considéré un mélange de $J = 3$ lois gaussiennes avec des moyennes très proches :

$$\alpha = (0,4, 0,4, 0,2), \quad m = (0,5, 1, 1,5), \quad v = (0,3, 0,2, 0,2).$$

Les moyennes ne sont espacées que de 0,5, ce qui entraîne un fort chevauchement entre les trois composantes. Les résultats montrent que l'algorithme converge, mais les paramètres estimés s'écartent sensiblement des vrais paramètres : les proportions, les moyennes et les variances sont toutes biaisées, avec par exemple une erreur de 0,08 sur $\alpha^{(1)}$ et de 0,19 sur $m^{(1)}$. Le graphique confirme visuellement ce décalage : les courbes estimées ne se superposent plus aux courbes vraies, contrairement au cas bien séparé. Néanmoins, le test de Kolmogorov-Smirnov appliqué sur un échantillon indépendant donne une p -valeur de 0,12, ce qui signifie que le mélange global reste acceptable au sens statistique. Autrement dit, l'algorithme parvient à reproduire la forme globale de la distribution, mais il échoue à identifier correctement chaque composante individuellement. Ce résultat illustre une limite fondamentale de l'algorithme EM : lorsque les composantes se chevauchent trop, les paramètres de chaque composante ne sont plus identifiables de manière fiable, même si le modèle dans son ensemble reste un bon ajustement.



4.1.4 Influence de la taille de l'échantillon

Pour étudier l'influence de la taille de l'échantillon sur la qualité de l'estimation, nous avons repris le cas des composantes proches ($m = (0,5, 1, 1,5)$) en augmentant la taille de l'échantillon de $n = 1000$ à $n = 40\,000$. Avec $n = 1000$, les estimations présentaient des écarts notables par rapport aux vrais paramètres, notamment sur les proportions ($\hat{\alpha}^{(1)} = 0,318$ au lieu de $0,4$) et les moyennes ($\hat{m}^{(1)} = 0,314$ au lieu de $0,5$). Avec $n = 40\,000$, on observe une amélioration : les moyennes estimées se rapprochent des vraies valeurs ($\hat{m}^{(1)} = 0,428$, $\hat{m}^{(2)} = 0,946$, $\hat{m}^{(3)} = 1,397$) et les variances sont mieux estimées. Cependant, les proportions restent biaisées ($\hat{\alpha}^{(1)} = 0,307$ au lieu de $0,4$), ce qui montre que même avec un échantillon très grand, le fort chevauchement entre les composantes empêche l'algorithme de séparer parfaitement les groupes. Par ailleurs, cette amélioration a un coût en temps de calcul : l'exécution passe d'environ 3 secondes pour $n = 1000$ à près d'une minute pour $n = 40\,000$, ce qui illustre le compromis entre précision et coût computationnel. L'augmentation de n réduit donc l'erreur d'estimation, mais ne suffit pas à résoudre le problème d'identifiabilité lié à la proximité des composantes. C'est une limite structurelle du modèle, indépendante de la taille de l'échantillon.





FIGURE 1 – Influence de la taille de l'échantillon sur les estimations

4.1.5 Sensibilité à l'initialisation et permutation des étiquettes

L'algorithme EM garantit que la log-vraisemblance augmente à chaque itération, mais pas l'ordre dans lequel les composantes sont numérotées. En effet, la vraisemblance du mélange est invariante par permutation des indices : échanger simultanément les triplets $(\alpha^{(j)}, m^{(j)}, v^{(j)})$ entre deux composantes ne modifie en rien la valeur de la vraisemblance. Ce phénomène, appelé *permutation des étiquettes*, peut amener l'algorithme à attribuer par exemple le label «composante 1» à ce qui correspond en réalité à l'espèce 3. Il ne s'agit cependant que d'un échange d'étiquettes portant sur le bloc complet des paramètres, puisque $\alpha^{(j)}$, $m^{(j)}$ et $v^{(j)}$ sont tous recalculés à partir des mêmes responsabilités $g_{\hat{\theta}}(j | X = X_i)$ et restent donc cohérents au sein de chaque composante. Pour y remédier lorsque les vrais labels sont connus, il suffit de comparer les moyennes estimées aux moyennes réelles et de réattribuer les numéros en conséquence.

Lorsque les vrais labels ne sont pas disponibles, la numérotation des composantes n'a aucune importance : ce qui compte, ce sont les valeurs des paramètres estimés, pas leur numéro. Le vrai problème en pratique est que l'algorithme peut s'arrêter sur une solution qui n'est pas la meilleure. Pour éviter cela, on le relance plusieurs fois avec des points de départ différents et on garde le meilleur résultat.

Cependant, cette réattribution n'est possible que si l'on dispose d'une information extérieure sur les groupes (connaissance préalable du domaine ou données déjà étiquetées), l'algorithme EM seul ne peut pas identifier à quoi correspond chaque composante, il se contente de détecter des groupes distincts dans les données.



La figure reprend le cas bien séparé $m = (-2, 0, 2)$, avec les vraies densités en pointillés et les densités estimées en trait plein. L'estimation est excellente : chaque courbe estimée recouvre une vraie courbe. En revanche, les couleurs ne coïncident plus. La composante estimée « Espèce 1 » (bleu) se situe en $+2$, alors que la vraie Espèce 1 est en -2 ; l'« Espèce 3 » estimée (vert) se retrouve quant à elle en -2 . Seule la composante centrale conserve son étiquette.

Ce décalage illustre la permutation des étiquettes : l'algorithme a parfaitement retrouvé les trois groupes, mais la numérotation qu'il leur attribue est arbitraire, puisque la vraisemblance est invariante par échange des indices. L'EM sépare donc les groupes sans pouvoir leur donner un sens ; lorsque les vraies étiquettes sont connues, il suffit de comparer les moyennes estimées aux moyennes réelles pour rétablir la correspondance.

4.2 Données réelles

4.2.1 Application sur le dataset Iris

Après avoir présenté les fondements théoriques de l'algorithme EM et du modèle de mélange de gaussiennes, nous allons maintenant appliquer cette méthode sur un jeu de données réel afin d'illustrer concrètement son fonctionnement.

Le jeu de données choisi est le célèbre *dataset* Iris, qui contient 150 observations de fleurs réparties en trois espèces : *Iris setosa*, *Iris versicolor* et *Iris virginica*. Chaque fleur est décrite par quatre mesures exprimées en centimètres : la longueur et la largeur du sépale, ainsi que la longueur et la largeur du pétale.

Dans cette application, nous faisons abstraction de la variable **Species** et nous laissons l'algorithme EM identifier lui-même les trois groupes naturels présents dans les données, uniquement à partir des mesures numériques. Cela nous permettra ensuite de comparer les clusters obtenus avec les vraies espèces et d'évaluer la qualité du modèle.

Choix de la variable :

L'algorithme EM développé dans ce travail étant univarié, il est nécessaire de choisir une seule des quatre variables disponibles. Pour identifier la plus discriminante, nous avons appliqué l'algorithme EM successivement sur chacune d'elles. La variable **PetalWidthCm** s'est révélée la plus performante, et c'est donc celle que nous retenons pour la suite de l'application.

```

1 Espèce 1 :
2   alpha estimé = 0.327   mu estimé = 0.237   var estimé = 0.009
3 Espèce 2 :
4   alpha estimé = 0.395   mu estimé = 1.369   var estimé = 0.065
5 Espèce 3 :
6   alpha estimé = 0.278   mu estimé = 2.087   var estimé = 0.06

```

Interprétation des résultats. L'algorithme EM identifie trois composantes gaussiennes dont les paramètres estimés correspondent étroitement aux trois espèces du dataset. Les moyennes estimées ($\hat{m}^{(1)} = 0,237$, $\hat{m}^{(2)} = 1,369$, $\hat{m}^{(3)} = 2,087$) coïncident avec les valeurs caractéristiques de *Iris setosa*, *Iris versicolor* et *Iris virginica* respectivement. Les proportions estimées sont proches d'un tiers pour chacune des trois espèces, ce qui est cohérent avec la composition équilibrée du dataset Iris (50 observations par espèce).

Références

- [1] C. F. J. Wu, *On the Convergence Properties of the EM Algorithm*, The Annals of Statistics, 11(1) :95–103, 1983. Disponible en ligne : <https://projecteuclid.org/journals/annals-of-statistics/volume-11/issue-1/On-the-Convergence-Properties-of-the-EM-Algorithm/10.1214/aos/1176346060.full>
- [2] A. P. Dempster, N. M. Laird, D. B. Rubin, *Maximum Likelihood from Incomplete Data via the EM Algorithm*, Journal of the Royal Statistical Society : Series B (Methodological), 39(1) :1–38, 1977. Disponible en ligne : <https://academic.oup.com/jrsssb/article/39/1/1/7027539>
- [3] D. Chafaï, F. Malrieu, *Recueil de modèles aléatoires*, Springer, Mathématiques et Applications, vol. 78, 2016. Disponible en ligne : <https://hal.science/hal-01897577/file/livre-with-fonts.pdf>