

Algorithme EM et mélanges

Mots-clés. Mélange de lois ; estimation paramétrique.

Outils. Formule de Bayes ; maximum de vraisemblance ; entropie relative ; loi gaussienne.

Difficulté. *

L'algorithme Expectation-Maximization (EM) fait partie des algorithmes les plus importants de la statistique. Il permet d'approcher numériquement l'estimateur de maximum de vraisemblance pour les modèles partiellement observés. De nombreuses variantes sont disponibles. Dans ce chapitre, nous illustrons la mécanique fondamentale de l'algorithme EM sur un exemple simple.

Sur une île cohabitent quatre espèces de mouettes différentes. Les ornithologues souhaitent estimer la proportion de mouettes de chaque espèce à partir de l'observation de la taille des nids. Contrairement aux oiseaux, les nids ne bougent pas, ce qui facilite le comptage. Malheureusement, les différentes espèces font des nids assez ressemblants : on ne sait pas par quelles espèces ils ont été construits. On suppose en revanche que la distribution des nids est caractéristique d'une espèce. La distribution globale de la taille des nids apparaît comme le mélange de quatre lois de probabilité, chacune rendant compte de la répartition de la taille des nids pour chaque espèce d'oiseaux.

8.1 Modèle pour les nids de mouettes

Modélisons la distribution de la taille des nids construits par l'espèce j par une loi $\mu_j = \mathcal{N}(m(j), v(j))$ de densité $\gamma_{m(j), v(j)}$. La loi μ de la taille des nids de mouettes admet donc pour densité la fonction

$$x \mapsto \sum_{j=1}^J \alpha(j) \gamma_{m(j), v(j)}(x) = \sum_{j=1}^J \frac{\alpha(j)}{\sqrt{2\pi v(j)}} \exp\left(-\frac{(x - m(j))^2}{2v(j)}\right),$$

avec $\alpha_1 > 0, \dots, \alpha_J > 0$ et $\alpha_1 + \dots + \alpha_J = 1$. Cette combinaison convexe finie de densités de probabilité est appelée mélange fini¹ de populations. Si X désigne la taille du nid et Z l'espèce de l'oiseau qui l'a construit, la loi du couple (X, Z) est donnée de la manière suivante :

— la variable Z suit la loi discrète sur $\{1, \dots, J\}$ de poids $\alpha(1), \dots, \alpha(J)$:

$$\text{Loi}(Z) = \sum_{j=1}^J \alpha(j) \delta_j$$

— pour tout $1 \leq j \leq J$, conditionnellement à $\{Z = j\}$, la variable X suit la loi $\mathcal{N}(m(j), v(j))$:

$$\text{Loi}(X|Z = j) = \mathcal{N}(m(j), v(j)).$$

Les paramètres $(\alpha_j, m(j), v(j))_{1 \leq j \leq J}$ sont inconnus. Le vecteur α représente les coefficients du mélange tandis que les vecteurs m et v représentent respectivement les vecteurs des moyennes et des variances des lois gaussiennes. On souhaite estimer toutes ces quantités à la seule vue de la taille de n nids. Pour cela, on suppose qu'il existe θ dans l'ensemble

$$\Theta = \left\{ \theta = (\alpha_j, m_j, \sigma_j^2)_{1 \leq j \leq J} : \alpha_1 > 0, \dots, \alpha_J > 0, \alpha_1 + \dots + \alpha_J = 1 \right\}$$

tel que les mesures $x_1, \dots, x_n$ de la taille de n nids soient la réalisation d'un n -échantillon $X_1, \dots, X_n$ de loi de densité au point x de la loi de X par rapport à la mesure de Lebesgue $d\lambda$ de $\mathbb{R}$

$$f_\theta(x) = \sum_{j=1}^J \alpha(j) \gamma_{m(j), v(j)}(x).$$

On note $\bar{X}$ le vecteur $(X_1, \dots, X_n)$ et $\bar{Z}$ le vecteur $(Z_1, \dots, Z_n)$. On note dN la mesure de comptage sur $\mathbb{N}$. On introduit les notations suivantes :

— densité au point (x, z) de la loi du couple (X, Z) par rapport à $d\lambda \otimes dN$:

$$h_\theta(x, z) = \alpha(z) \gamma_{m(z), v(z)}(x), \quad x \in \mathbb{R}, \quad z \in \{1, \dots, J\},$$

— densité au point x de la loi de X par rapport à $d\lambda$:

$$f_\theta(x) = \sum_{j=1}^J \alpha(j) \gamma_{m(j), v(j)}(x), \quad x \in \mathbb{R},$$

— densité au point z de la loi de Z par rapport à la mesure dN :

$$g_\theta(z) = \alpha(z), \quad z \in \{1, \dots, J\},$$

1. «*Finite mixture*» en anglais.

— densité au point x de la loi de X sachant Z par rapport à $d\lambda$:

$$f_\theta(x|Z=j) = \gamma_{m(j),v(j)}(x), \quad x \in \mathbb{R},$$

— densité au point z de la loi de Z sachant X par rapport à dN :

$$g_\theta(z|X=x) = \frac{\alpha(z)\gamma_{m(z),v(z)}(x)}{\sum_{j=1}^J \alpha(j)\gamma_{m(j),v(j)}(x)}, \quad z \in \{1, \dots, J\}.$$

La dernière expression s'obtient grâce à la définition d'une probabilité conditionnelle : en effet, pour tout A borélien et tout $1 \leq z \leq J$,

$$\mathbb{P}(X \in A, Z = z) = \mathbb{P}(Z = z)\mathbb{P}(X \in A|Z = z) = \alpha(z) \int_A \gamma_{m(z),v(z)}(x) dx$$

et

$$\begin{aligned} \mathbb{P}(X \in A, Z = z) &= \mathbb{P}(Z = z|X \in A)\mathbb{P}(X \in A) \\ &= \mathbb{P}(Z = z|X \in A) \sum_{j=1}^J \alpha(j) \int_A \gamma_{m(j),v(j)}(x) dx, \end{aligned}$$

de sorte que si A est de la forme $[x - \varepsilon, x + \varepsilon]$ avec ε tendant vers 0, alors on obtient bien

$$\alpha(z)\gamma_{m(z),v(z)}(x) = \mathbb{P}(Z = z|X = x) \sum_{j=1}^J \alpha(j)\gamma_{m(j),v(j)}(x).$$

8.2 Situation favorable mais irréaliste

On suppose dans cette section que l'on observe à la fois X et Z , c'est-à-dire à la fois la taille du nid et l'espèce qui a fait le nid. Estimer les paramètres inconnus est alors aisé grâce à la méthode du maximum de vraisemblance. La log-vraisemblance du modèle complet (logarithme de la densité de la loi de l'échantillon $(\overline{X}, \overline{Z})$ par rapport à la mesure $(d\lambda \otimes dN)^{\otimes n}$) s'écrit

$$\begin{aligned} L(\theta, \overline{X}, \overline{Z}) &= \log \prod_{i=1}^n h_\theta(X_i, Z_i) \\ &= \sum_{i=1}^n [\log \alpha(Z_i) + \log \gamma_{m(Z_i),v(Z_i)}(X_i)]. \end{aligned}$$

Pour un échantillon de taille n , notons, pour tout $1 \leq j \leq J$,

$$A_j = \{i = 1, \dots, n, Z_i = j\} \quad \text{et} \quad C_j = \text{card}(A_j).$$

En regroupant les termes en fonction des valeurs possibles de $\overline{Z}$, on obtient

$$L(\theta, \overline{X}, \overline{Z}) = \sum_{j=1}^J C_j \log \alpha(j) + \sum_{j=1}^J \sum_{i \in A_j} \log \gamma_{m(j),v(j)}(X_i).$$

Théorème 8.1 (Estimation pour modèle complet). *La vraisemblance complète atteint son maximum en un point unique $\hat{\theta} \in \Theta$ donné par :*

$$\hat{\alpha}(j) = \frac{C_j}{n}, \quad \hat{m}(j) = \frac{1}{C_j} \sum_{i \in A_j} X_i \quad \text{et} \quad \hat{v}(j) = \frac{1}{C_j} \sum_{i \in A_j} (X_i - \hat{m}(j))^2.$$

Démonstration. Sous la contrainte $\alpha(1) + \dots + \alpha(J) = 1$, la fonction $\theta \mapsto L(\theta, \bar{X}, \bar{Z})$ admet un unique point critique, qui s'avère être un maximum. $\square$

Ce résultat ne répond pas à la question initiale puisque, en pratique, ne sont observées que les tailles des nids $x_1, \dots, x_n$. Il faudrait plutôt étudier la log-vraisemblance de l'échantillon $X_1, \dots, X_n$, notée L_{obs} pour log-vraisemblance des observations, qui s'écrit :

$$L_{\text{obs}}(\theta, \bar{X}) = \log \prod_{i=1}^n f_{\theta}(X_i) = \sum_{i=1}^n \log \left[\sum_{j=1}^J \alpha(j) \gamma_{m(j), v(j)}(X_i) \right].$$

Trouver un jeu de paramètres θ qui maximise cette quantité n'est pas facile.

8.3 Résolution du vrai problème

Ne disposant pas de la log-vraisemblance complète L , on la remplace par son espérance conditionnelle sachant les observations : on définit la log-vraisemblance conditionnelle des observations sous la loi de paramètre θ , que nous noterons $L_c(\theta, \tilde{\theta}, \bar{X})$, par :

$$L_c(\theta, \tilde{\theta}, \bar{X}) = \mathbb{E}_{\tilde{\theta}}(L(\theta, \bar{X}, \bar{Z}) | \bar{X}) = \sum_{i=1}^n \sum_{j=1}^J \log h_{\theta}(X_i, j) g_{\tilde{\theta}}(j | X = X_i).$$

Voici l'expression de la vraisemblance conditionnelle L_c dans notre cadre de mélange gaussien.

Théorème 8.2 (Log-vraisemblance conditionnelle). *La fonction L_c est de la forme suivante :*

$$\begin{aligned} L_c(\theta, \tilde{\theta}, \bar{X}) = & -\frac{n}{2} \log(2\pi) + \sum_{j=1}^J \left(\sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) \right) \log \alpha(j) \\ & - \frac{1}{2} \sum_{j=1}^J \left(\sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) \right) \left(\log v(j) + \frac{(X_i - m(j))^2}{v(j)} \right). \end{aligned}$$

Il est aisé de déterminer le maximum de la vraisemblance conditionnelle.

Théorème 8.3 (Maximum de la log-vraisemblance conditionnelle). *La fonction $\theta \mapsto L_c(\theta, \bar{\theta}, \bar{X})$ admet un unique maximum θ_M donné par*

$$\begin{aligned}\alpha_M(j) &= \frac{1}{n} \sum_{i=1}^n g_{\bar{\theta}}(j|X = X_i) \\ m_M(j) &= \frac{\sum_{i=1}^n X_i g_{\bar{\theta}}(j|X = X_i)}{\sum_{i=1}^n g_{\bar{\theta}}(j|X = X_i)} \\ v_M(j) &= \frac{\sum_{i=1}^n (X_i - m_M(j))^2 g_{\bar{\theta}}(j|X = X_i)}{\sum_{i=1}^n g_{\bar{\theta}}(j|X = X_i)}.\end{aligned}$$

Démonstration. Sous la contrainte $\alpha(1) + \dots + \alpha(J) = 1$, on trouve

$$\alpha_M(j) = \frac{\sum_{i=1}^n g_{\bar{\theta}}(j|X = X_i)}{\sum_{l=1}^J \sum_{i=1}^n g_{\bar{\theta}}(l|X = X_i)} = \frac{1}{n} \sum_{i=1}^n g_{\bar{\theta}}(j|X = X_i).$$

D'autre part (m_M, v_M) est un point critique du dernier terme de la log-vraisemblance conditionnelle. $\square$

L'algorithme EM consiste à répéter successivement deux étapes consécutives comme suit :

- étape E(xpectation) : étant donnée une valeur θ_k du paramètre, on calcule la log-vraisemblance conditionnelle des observations $L_c(\theta, \theta_k, \bar{X})$ avec le théorème 8.2,
- étape M(aximisation) : grâce au théorème 8.3, on choisit θ_{k+1} pour que la fonction $\theta \mapsto L_c(\theta, \theta_k, \bar{X})$ soit maximale au point θ_{k+1} .

En pratique, étant données les observations $x_1, \dots, x_n$ et des valeurs initiales des paramètres, l'algorithme consiste à répéter les calculs suivants :

- à partir du paramètre θ_k , on calcule la matrice $H^{(k)}$ de taille $n \times J$ suivante

$$H_{ij}^{(k)} = \frac{\alpha_k(j) \gamma_{m_k(j), v_k(j)}(X_i)}{\sum_{l=1}^J \alpha_k(l) \gamma_{m_k(l), v_k(l)}(X_i)},$$

- on en déduit θ_{k+1} par les relations suivantes :

$$\begin{aligned}\alpha_{k+1}(j) &= \frac{1}{n} \sum_{i=1}^n H_{ij}^{(k)}, \\ m_{k+1}(j) &= \frac{\sum_{i=1}^n X_i H_{ij}^{(k)}}{\sum_{i=1}^n H_{ij}^{(k)}}, \\ v_{k+1}(j) &= \frac{\sum_{i=1}^n (X_i - m_{k+1}(j))^2 H_{ij}^{(k)}}{\sum_{i=1}^n H_{ij}^{(k)}}.\end{aligned}$$

Le théorème 8.3 ne vaut que si nous savons estimer $\bar{\theta}$. Dans l'algorithme EM, ceci est fait numériquement. Le résultat suivant montre que la log-vraisemblance L_{obs} est croissante le long de l'algorithme.

Théorème 8.4 (Croissance de la vraisemblance). *La suite $(\theta_k)_{k \geq 0}$ construite par l'algorithme EM vérifie la propriété de stabilité numérique suivante :*

$$L_{\text{obs}}(\theta_{k+1}, \bar{X}) \geq L_{\text{obs}}(\theta_k, \bar{X}),$$

où $L_{\text{obs}}(\theta, \bar{X})$ est la log-vraisemblance des observations.

Démonstration. Posons

$$H(\theta, \theta_k) = \mathbb{E}_{\theta_k}(\log g_{\theta}(\bar{Z} | \bar{X})) = \sum_{i=1}^n \mathbb{E}_{\theta_k}(\log g_{\theta}(Z_i | X_i)).$$

Puisque $h_{\theta}(x, z) = f_{\theta}(x)g_{\theta}(z|X=x)$, la vraisemblance conditionnelle s'écrit

$$L_c(\theta, \theta_k, \bar{X}) = L_{\text{obs}}(\theta, \bar{X}) + H(\theta, \theta_k).$$

Lors de l'étape M, la fonction $\theta \mapsto L_c(\theta, \theta_k, \bar{X})$ est maximisée en θ , d'où

$$L_c(\theta_{k+1}, \theta_k, \bar{X}) \geq L_c(\theta_k, \theta_k, \bar{X}).$$

On en déduit que

$$L_{\text{obs}}(\theta_{k+1}, \bar{X}) - L_{\text{obs}}(\theta_k, \bar{X}) \geq H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k).$$

Par définition de H ,

$$H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k) = \mathbb{E}_{\theta_k} \log \frac{g_{\theta_k}(\bar{Z} | \bar{X})}{g_{\theta_{k+1}}(\bar{Z} | \bar{X})}.$$

En notant μ_{θ} la loi de $\bar{Z}$ sachant $\bar{X}$ sous $\mathbb{P}_{\theta}$, on remarque que la quantité ci-dessus n'est rien d'autre que l'entropie relative de μ_{θ_k} par rapport à $\mu_{\theta_{k+1}}$:

$$H(\theta_k, \theta_k) - H(\theta_{k+1}, \theta_k) = \int \log \frac{d\mu_{\theta_k}}{d\mu_{\theta_{k+1}}} d\mu_{\theta_k} = \int \frac{d\mu_{\theta_k}}{d\mu_{\theta_{k+1}}} \log \frac{d\mu_{\theta_k}}{d\mu_{\theta_{k+1}}} d\mu_{\theta_{k+1}}.$$

L'inégalité de Jensen assure que cette quantité est positive. $\square$

Le théorème 8.4 montre que la suite $(L_{\text{obs}}(\theta_k, \bar{X}))_{k \geq 0}$ est croissante. Elle converge donc vers un point critique (maximum local ou point selle) de la vraisemblance $L_{\text{obs}}(\cdot, \bar{X})$. Contrairement au cas où l'on observe en même temps X et Z , il peut exister des maxima locaux qui vont piéger l'algorithme, ce qui rend le résultat sensible au point de départ. On peut améliorer le comportement de l'algorithme en incorporant un peu d'aléa, comme par exemple dans l'algorithme du recuit simulé du chapitre 4, mais cela est un peu illusoire. De plus on ne sait pas combien d'itérations sont requises pour approcher suffisamment un maximum local. Il n'y a pas de critère d'arrêt performant.

La figure 8.1 donne l'estimation du mélange de trois gaussiennes par l'algorithme EM avec 1000 itérations et les paramètres

$$\alpha = (0.4 \ 0.4 \ 0.2), \quad m = (-2 \ 0 \ 2), \quad v = (0.3 \ 0.2 \ 0.2), \quad n = 1000.$$




Fig. 8.1. Estimation du mélange de trois gaussiennes par l'algorithme EM.

8.4 Pour aller plus loin

Le théorème 8.3 se généralise aux familles exponentielles, de vraisemblance totale

$$L(\theta, \bar{x}, \bar{z}) = \sum_{i=1}^n \log h_{\theta}(x_i, z_i) = \sum_{i=1}^n \log g_{\theta}(z_i) + \sum_{i=1}^n \log f_{\theta}(x_i | Z = z_i).$$

Après intégration, il vient en rappelant que $g_{\theta}(z) = \alpha(z)$,

$$\begin{aligned} L_c(\theta, \tilde{\theta}, \bar{x}) &= \sum_{j=1}^J \left(\sum_{i=1}^n g_{\tilde{\theta}}(j | X = x_i) \right) \log \alpha(j) \\ &\quad + \sum_{j=1}^J \sum_{i=1}^n g_{\tilde{\theta}}(j | X = x_i) \log f_{\theta}(x_i | Z = j). \end{aligned}$$

Si $\theta = (\alpha, \beta)$ où α est encore la loi mélange et $\beta(j)$ représente les paramètres de la loi $\text{Loi}(X | Z = j)$, on détermine séparément α_M (qui a toujours la même expression) et β_M qui s'obtient quasiment comme pour le maximum de la vraisemblance totale : on a seulement pondéré la contribution de l'observation X_i par le coefficient $g_{\tilde{\theta}}(j | X = x_i)$. Par exemple, si les composantes du mélange $(\text{Loi}(X | Z = j))_{1 \leq j \leq J}$ sont des lois exponentielles de paramètres $(\lambda(i))_{1 \leq i \leq J}$, la log-vraisemblance conditionnelle s'écrit

$$\begin{aligned}
L_c(\theta, \tilde{\theta}, \overline{X}) &= \sum_{j=1}^J \left(\sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) \right) \log \alpha(j) \\
&\quad + \sum_{j=1}^J \sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i) (\log \lambda(j) - \lambda(j) x_i).
\end{aligned}$$

Un pas de l'algorithme EM a la forme suivante :

$$\begin{aligned}
H_{ij}^{(k)} &= \frac{\alpha_k(j) \lambda_k(j) e^{-\lambda_k(j) x_i}}{\sum_{l=1}^J \alpha_k(l) \lambda_k(l) e^{-\lambda_k(l) x_i}}, \\
\alpha_{k+1}(j) &= \frac{1}{n} \sum_{i=1}^n H_{ij}^{(k)}, \\
\lambda_{k+1}(j) &= \frac{\sum_{i=1}^n H_{ij}^{(k)}}{\sum_{i=1}^n X_i H_{ij}^{(k)}}.
\end{aligned}$$

Si de nombreux travaux existaient déjà autour de cette question, c'est véritablement l'article [DLR77] de Arthur Dempster, Nan Laird, et Donald Rubin qui définit pour la première fois l'algorithme EM dans un cadre général. On trouvera dans la bibliographie de ce travail les références aux résultats antérieurs. Depuis, cet algorithme est très souvent utilisé dans des cadres et sous des formes variés. Pour réduire la dépendance aux conditions initiales, de nombreuses versions randomisées de l'algorithme EM ont été développées, inspirées notamment de l'algorithme d'approximation stochastique de Kiefer-Wolfowitz pour le calcul du maximum de fonction sous forme d'espérance, lui-même inspiré de l'algorithme d'approximation stochastique de Robbins-Monro pour le calcul de zéro de fonction sous forme d'espérance. On pourra par exemple consulter à ce sujet l'article [DLM99] de Bernard Delyon, Marc Lavielle, et Éric Moulines, et le livre [Duf97] de Marie Duflo. Lorsqu'il n'est pas possible de calculer la log-vraisemblance conditionnelle, on peut utiliser une méthode de Monte-Carlo comme l'algorithme de Metropolis-Hastings du chapitre 5 pour obtenir une approximation de cette fonction dont on cherche ensuite un maximum numériquement. Ce type d'approche est étudié par exemple par Estelle Kuhn et Marc Lavielle dans [KL04].

Une étude de la dégénérescence de la vraisemblance des mélanges finis gaussiens et ses liens avec l'algorithme EM est menée par Christophe Biernacki et Stéphane Chrétien dans [BC03].